



Université de Carthage
Institut des Hautes Études Commerciales de Carthage

Rapport de Projet de Fin d'Études

Présenté en vue de l'obtention du diplôme de :
Licence en Business Computing
Spécialité : Business Intelligence

Construction d'un score ESG et modélisation prédictive : de l'étude expérimentale à la plateforme décisionnelle

Élaboré par :
Tasnim DISSEM & Yasmine BENMOHAMED

Encadrant académique

Dr. Jihene TOUNSI

Encadrants professionnels

M. Mohamed Amine KILANI

M. Mohamed BESBES

Organisme d'accueil :



Année universitaire : 2025–2026

Dédicaces

À mon père, **Ali**, aucun mot ne saurait exprimer pleinement ma gratitude pour tout ce que tu as fait pour moi. Merci pour ton amour inconditionnel, tes sacrifices, ta confiance et ton soutien constant à chaque étape de mon parcours. Ta force, ta générosité et les valeurs que tu m'as transmises ont toujours été ma source d'inspiration. Si j'arrive aujourd'hui au terme de cette aventure, c'est en grande partie grâce à toi. Ce travail est le fruit de tes efforts autant que des miens.

À ma mère, **Leila**, pour ton affection infinie, ta bienveillance et ton soutien sans faille. Merci d'avoir toujours cru en moi, de m'avoir encouragée dans les moments de doute et d'avoir été une présence rassurante tout au long de mon parcours. Ton amour et tes sacrifices ont été un pilier essentiel de ma réussite.

À mon frère **Mohamed Amine** et à ma sœur **Lina**, pour leur affection, leur patience et leurs encouragements sincères, qui m'ont accompagnée dans les moments de doute comme dans les moments de réussite.

À mes précieuses amies **Elaa, Ghalia** et **Manar**, dont l'écoute, la gentillesse et le soutien indéfectible m'ont accompagnée tout au long de cette aventure. Leur présence a grandement contribué à rendre ce parcours plus serein et plus enrichissant.

À **Yasmine**, ma binôme, merci pour ton implication, ta fiabilité et ton soutien tout au long de cette aventure. Ta détermination, ton sens de l'organisation et ton aptitude à trouver des solutions ont été d'une valeur inestimable.

À ma cousine **Yasmine**, merci d'avoir partagé avec moi les joies, les doutes et les défis de cette aventure. Ton soutien m'a été précieux.

À toutes les personnes qui, de près ou de loin, ont participé à cette aventure et occupent une place particulière dans mon cœur, je dédie ce travail avec gratitude et reconnaissance.

Tasnim DISSEM

Dédicaces

À mon cher père, Dr. Souheil BENMOHAMED, l'homme qui n'a jamais cessé de croire en moi. Grâce à ton soutien indéfectible et à tes encouragements, je suis là où je suis aujourd'hui. Tu es ma source d'inspiration. C'est grâce à toi que je rêve de toujours évoluer, de donner chaque jour un peu plus de moi-même, pour toucher du doigt une infime parcelle de ton succès. Tu travailles jours et nuits pour assurer notre avenir : je te dédie tous mes efforts.

À tata Ilhem, la femme dont l'amour et la présence ont illuminé mon chemin. Je suis infiniment reconnaissante à la douce coïncidence qui nous a réunies. Je n' imagine plus ma vie sans toi à mes côtés. Chaque heure qui passe sans te voir m'est difficile. Ma voisine, mon repère, ma source de passion et d'amour : je rêve de t'avoir toujours près de moi.

À mes élèves, du premier que j'ai enseigné jusqu'au dernier groupe de baccalauréat, vous êtes ma source d'inspiration sans le savoir. C'est grâce à vous que j'enseigne avec espoir chaque jour, que je rêve de progresser dans ce noble métier et que je cherche à être toujours plus créative dans ma façon de transmettre.

À ma binôme Tasnim, merci pour cette collaboration harmonieuse et apaisante, sans heurts ni frustrations. Tes qualités et compétences ont parfaitement équilibré les miennes, et je te suis profondément reconnaissante d'avoir partagé ce projet avec toi.

Yasmine BENMOHAMED

Remerciements

Cette page est destinée à toutes les personnes ayant contribué à la réalisation de ce projet. C'est avec un immense honneur que nous écrivons ces mots afin de leur témoigner notre reconnaissance.

Tout d'abord, nous tenons à rendre grâce à Dieu pour nous avoir guidés durant chaque étape de ce travail, et pour nous avoir donné la force et la détermination nécessaires pour mener ce projet à bien.

Nous souhaitons exprimer notre profonde gratitude à **Dr. Jihene TOUNSI**, notre encadrante académique, pour l'aide précieuse, les conseils avisés et le savoir qu'elle nous a transmis. Chacune de nos discussions a permis une meilleure orientation de nos travaux, nous évitant ainsi de nous égarer.

Nous tenons également à remercier **M. Mohamed Amine KILANI** et **M. Mohamed BESBES**, nos superviseurs professionnels, pour la qualité de leur encadrement. Leur expertise, leur savoir-faire ainsi que leur soutien constant ont été des éléments clés pour le bon déroulement de notre stage dans les meilleures conditions possibles.

Enfin, nous témoignons notre reconnaissance à l'**Institut des Hautes Études Commerciales de Carthage (IHEC Carthage)**, pour nous avoir offert un cadre d'apprentissage stimulant, propice à notre épanouissement académique et à notre préparation au monde professionnel. Nous remercions également les **membres du jury** d'avoir pris le temps d'évaluer notre travail et d'enrichir ce projet par leurs remarques.

Table des matières

Introduction générale	1
1 Cadre général du projet	3
Introduction	3
1.1 Présentation de l'organisme d'accueil	3
1.1.1 Identité et expertises de Tritux Group	3
1.1.2 Positionnement stratégique	4
1.2 Contexte ESG	4
1.2.1 Importance des critères extra-financiers	4
1.2.2 Problème de l'incertitude informationnelle	5
1.3 Présentation du projet	5
1.3.1 Problématique	5
1.3.2 Objectifs	5
1.3.3 Organisation et jalons	6
1.4 Cadres méthodologiques pour les projets de Data Science	6
1.4.1 KDD	6
1.4.2 SEMMA	6
1.4.3 CRISP-DM	7
1.4.4 Justification du choix de CRISP-DM	7
1.4.5 Application au projet ESG	7
1.5 Environnement de développement	8
1.5.1 Environnement matériel	8
1.5.2 Langages & outils de développement	9
1.5.3 Frameworks & technologies	10
1.5.4 Outils de conception & collaboration	10
Conclusion	11
2 Exploration et analyse des données	12
Introduction	12
2.1 Acquisition des données	12
2.2 Description du dataset	13

2.2.1	Structure des données	13
2.2.2	Période et taille du dataset	13
2.2.3	Types de variables	13
2.2.4	Qualité des données	13
2.3	Taxonomie et Dictionnaire des Variables	13
2.4	Analyse exploratoire des données (EDA)	16
2.4.1	Asymétrie distributionnelle	17
2.4.2	Anomalies et valeurs suspectes	18
2.5	Analyse des corrélations entre variables	19
2.6	Prétraitement et raffinement des données ESG	20
2.6.1	Nettoyage et validation	20
2.6.2	Atténuation des valeurs extrêmes	20
2.6.3	Transformation logarithmique et traitement de la skewness résiduelle	20
2.6.4	Calculs, stabilisation et normalisation des indicateurs d'intensité	21
2.6.5	Détection des outliers multivariés	21
2.6.6	Décision finale concernant les outliers multivariés	22
2.6.7	Standardisation robuste	22
2.7	Validation finale : Audit du dataset traité	22
2.7.1	Validation de la correction du biais de rémunération	23
2.7.2	Vérification de la distribution des variables transformées	23
2.7.3	Validation de la structure de corrélation	24
	Conclusion	25

3 Approche initiale : Évaluation critique du clustering pour la segmentation ESG 26

	Introduction	26
3.1	Algorithmes et métriques d'évaluation	26
3.1.1	Choix des modèles	26
3.1.2	Métriques d'évaluation	27
3.1.3	Optimisation des hyperparamètres	28
3.2	Évaluation : analyse des performances du clustering	29
3.2.1	Résultats quantitatifs	29
3.2.2	Résultats qualitatifs	30
3.3	Discussion : le continuum ESG	31
3.3.1	Visualisation spatiale et limites de la classification	31
3.3.2	La nature continue de la performance ESG	32
	Conclusion	32

4	Approche avancée : du clustering au scoring continu	33
	Introduction	33
4.1	Redéfinition de la compréhension métier : du clustering au scoring	33
4.1.1	Pivot de l'objectif : de la « catégorie » à la « performance relative »	33
4.1.2	Le problème du biais géographique	33
4.2	Diagnostic des échecs du scoring traditionnel	34
4.2.1	Approche 1 : La moyenne simple	34
4.2.2	Approche 2 : La pondération arbitraire	35
4.2.3	Échec commun : écrasement de la variance	35
4.3	Solution : L'Analyse en Composantes Principales (ACP) Hiérarchique . . .	36
4.3.1	Nettoyage des colinéarités : une étape préalable indispensable . . .	36
4.3.2	ACP de niveau 1 : synthétiser chaque pilier	36
4.3.3	ACP de niveau 2 : la pondération naturelle	37
4.3.4	Normalisation par rangs : une distribution uniforme	38
4.3.5	Neutralisation géographique : comparer des pairs locaux	39
4.4	Robustesse Statistique du Score pour le Machine Learning	39
4.4.1	Analyse des corrélations	39
4.4.2	Validation de la distribution	40
4.4.3	Pouvoir discriminant : Courbe de Lorenz	40
	Conclusion	41
5	Modélisation prédictive de la performance ESG	42
	Introduction	42
5.1	Préparation des données et stratégie d'échantillonnage	42
5.1.1	Rupture structurelle : le cas de l'exercice 2020	42
5.1.2	Intégrité prédictive et prévention de la circularité	43
5.1.3	Codage de la variable sectorielle	44
5.2	Modèles d'apprentissage automatique	44
5.2.1	Régression linéaire et ElasticNet	44
5.2.2	Arbre de décision	44
5.2.3	Support Vector Regression (SVR)	45
5.2.4	Random Forest	45
5.2.5	Gradient Boosting : XGBoost, LightGBM, CatBoost	45
5.2.6	Comparaison des modèles	45
5.3	Évaluation et optimisation des modèles	46
5.3.1	Métriques d'évaluation	46
5.3.2	Optimisation des hyperparamètres et validation	47
5.4	Résultats et évaluation	47
5.4.1	Comparaison des performances	47

5.4.2	Analyse des résultats	47
5.5	Validation et interprétation du modèle CatBoost	47
5.5.1	Analyse de la précision et des résidus	48
5.5.2	Importance des variables et transparence de l’audit	49
	Conclusion	50
6	Architecture, Développement et Déploiement de la Plateforme ESG	51
6.1	Capture des besoins	51
6.1.1	Identification des acteurs	51
6.1.2	Besoins fonctionnels	53
6.1.3	Besoins non fonctionnels	55
6.1.4	Diagramme de cas d’utilisation	56
6.1.5	Diagramme de classes	57
6.1.6	Diagrammes de séquence	57
6.1.7	Choix technologiques & Architecture	60
6.2	Architecture & Déploiement	61
6.2.1	Authentification & gestion des rôles	62
6.2.2	Administration de la plateforme	65
6.2.3	Gestion des entreprises	66
6.2.4	Module de prédiction ESG	68
6.2.5	Analyse ESG et visualisations	70
6.2.6	Gestion du profil utilisateur	71
6.2.7	Système de recommandation ESG	71
6.2.8	Assistant conversationnel (Chatbot RAG) — <i>ESGénie</i>	72
6.2.9	Agrégation d’actualités ESG	73
6.2.10	Implémentation du modèle de Machine Learning	74
6.3	Conception et développement du tableau de bord analytique	74
6.3.1	Architecture de la solution analytique	74
6.3.2	Modélisation des données : architecture en flocon de neige	75
6.3.3	Indicateurs clés (mesures DAX)	76
6.3.4	Pages du tableau de bord	77
6.3.5	Description détaillée des pages	78
6.3.6	Interactivité et navigation	81
6.4	Implémentation du système RAG	82
6.4.1	Vue d’ensemble & architecture	82
6.4.2	Pipeline de traitement	82
6.4.3	Embeddings & vectorisation	82
6.4.4	Chunking & prétraitement	82
6.4.5	Base vectorielle FAISS & indexation	83

6.4.6	Recherche & scoring de similarité	83
6.4.7	Construction du prompt & génération	84
6.4.8	Mécanisme de fallback LLM	85
6.5	Tests et validation	85
6.6	Sécurité & optimisation	87
6.7	Conclusion	87
Conclusion générale et perspectives		88
Bibliographie		90

Table des figures

1.1	Logo de l'entreprise Tritux Group	3
1.2	Processus itératif CRISP-DM	8
2.1	Distributions des variables (échelle semi-logarithmique) : mise en évidence de la forte asymétrie positive initiale	17
2.2	Répartition sectorielle des entreprises à revenu négatif.	18
2.3	Répartition temporelle des observations à revenu négatif.	18
2.4	Matrice de corrélation de Spearman des variables numériques brutes	19
2.5	Pipeline de prétraitement des données ESG	20
2.6	Impact de l'introduction des ratios d'intensité sur la détection des anomalies multidimensionnelles	22
2.7	Comparaison de la distribution de la rémunération CEO avant et après winsorisation	23
2.8	Distributions finales des variables après pipeline de prétraitement	24
2.9	Matrice de corrélation après prétraitement	25
3.1	Évolution de l'Adjusted Rand Index (ARI) entre K-Means et GMM en fonction de k	28
3.2	Évolution du score de Silhouette pour K-Means et GMM en fonction de k .	29
3.3	Évolution des critères BIC et AIC pour le modèle GMM en fonction de k .	29
3.4	Niveau de consensus entre les trois algorithmes de <i>clustering</i> ($k = 7$). . . .	31
3.5	Projection ACP des observations ESG par classe de consensus (PC1 : 35,2 %, PC2 : 16,4 % de variance expliquée).	32
4.1	Intensité carbone moyenne (Scope 1 / CA) par pays	34
4.2	Distribution (KDE) des scores obtenue par moyenne simple et pondération arbitraire : mise en évidence de la faible dispersion	35
4.3	Corrélations entre les scores des piliers ESG.	37
4.4	Poids des piliers E, S et G extraits de PC1 au niveau 2	38
4.5	Distribution du score ESG avant (loi normale) et après normalisation par rangs (loi uniforme).	38
4.6	Distribution du score ESG par pays avant neutralisation	39

4.7	Distribution du score ESG par pays après neutralisation	39
4.8	Corrélations piliers–score ESG global après neutralisation géographique. . .	40
4.9	Courbe de Lorenz du score ESG final : distribution uniforme sur $[0, 100]$. .	41
5.1	Évolution moyenne des scores ESG par année (2018–2020)	43
5.2	Volume d’observations pour les 10 secteurs prédominants (sur 154)	44
5.3	Comparaison des scores ESG réels et prédits (CatBoost, échantillon 2020) .	48
5.4	Distribution des résidus du modèle CatBoost	48
5.5	Importance SHAP des variables (contribution moyenne)	49
6.1	Diagramme de cas d’utilisation de la plateforme ESG	56
6.2	Diagramme de classes	57
6.3	Diagramme de séquence — Authentification	58
6.4	Diagramme de séquence — Prédiction ESG	59
6.5	Diagramme de séquence — Chatbot RAG (ESGénie)	60
6.6	Architecture générale de la plateforme ESG	62
6.7	Page de connexion	63
6.8	Identifiants incorrects	63
6.9	Page d’inscription	64
6.10	E-mail d’activation reçu après approbation	64
6.11	Page de réinitialisation du mot de passe	65
6.12	E-mail de réinitialisation reçu par l’utilisateur	65
6.13	Page de saisie du nouveau mot de passe	65
6.14	Panneau d’administration — gestion des utilisateurs et des rôles	66
6.15	Interface de gestion des entreprises — liste et actions CRUD	67
6.16	Création d’une entreprise	67
6.17	Confirmation de suppression	67
6.18	Historique des scores ESG et évolution temporelle	68
6.19	Formulaire de saisie des métriques ESG — ESG Studio	69
6.20	Résultat de la prédiction — Score ESG global et interprétation	70
6.21	Module d’analytics ESG — visualisations et comparaisons	71
6.22	Page de gestion du profil utilisateur	71
6.23	Système de recommandation ESG — cartes d’action personnalisées	72
6.24	Interface du chatbot <i>ESGénie</i> — réponse RAG avec sources documentaires	72
6.25	Interrogation vocale du chatbot <i>ESGénie</i>	73
6.26	Module d’agrégation des actualités ESG	74
6.27	Architecture du pipeline analytique Power BI	75
6.28	Modèle relationnel Power BI – schéma en flocon de neige	76
6.29	Page Navigation : accueil et boutons de navigation vers les cinq pages. . .	78
6.30	Page Vue d’ensemble.	78

6.31	Page Analyse sectorielle.	79
6.32	Page Analyse par entreprise.	79
6.33	Page Prédiction CatBoost.	80
6.34	Page Intensités environnementales.	81
6.35	Pipeline RAG de traitement des requêtes ESG	82

Liste des tableaux

1.1	Domaines d'expertise de Tritux Group	4
1.2	Solutions et services proposés par Tritux Group	4
1.3	Comparaison des méthodologies KDD, SEMMA et CRISP-DM [58]	7
1.4	Caractéristiques matérielles de la première machine	9
1.5	Caractéristiques matérielles de la deuxième machine	9
2.1	Dictionnaire des variables du panel ESG	14
3.1	Évolution du score de Silhouette et de l'ARI selon k (K-Means et GMM)	30
3.2	Répartition des observations par niveau de consensus algorithmique.	30
4.1	Synthèse de l'ACP de Niveau 1 par pilier ESG.	36
5.1	Structure de l'échantillon par période	43
5.2	Comparatif des modèles de Machine Learning.	45
5.3	Tableau comparatif des performances des modèles sur l'année de test (2020)	47
6.1	Synthèse des acteurs de la plateforme ESG	53
6.2	Besoins fonctionnels de la plateforme ESG	54
6.3	Besoins non fonctionnels de la plateforme ESG	55
6.4	Environnement technologique de la plateforme ESG	61
6.5	Récapitulatif des sources de données	75
6.6	Structure et objectifs des pages du tableau de bord	77
6.7	Fonctionnalités d'interactivité	81
6.8	Évolution des paramètres de retrieval au cours du développement	83
6.9	Exemples de cas de test API	86
6.10	Exemples de tests qualitatifs du système RAG	86

Liste des acronymes

AIC	Akaike Information Criterion
ANOVA	Analysis of Variance
API	Application Programming Interface
ARI	Adjusted Rand Index
BIC	Bayesian Information Criterion
BM25	Best Match 25
CORS	Cross-Origin Resource Sharing
CRISP-DM	CRoss-Industry Standard Process for Data Mining
CRUD	Create, Read, Update, Delete
CSRF	Cross-Site Request Forgery
DAX	Data Analysis Expressions
EDA	Exploratory Data Analysis
ESG	Environnemental, Social et de Gouvernance
FAISS	Facebook AI Similarity Search
GES	Gaz à Effet de Serre
GICS	Global Industry Classification Standard
GMM	Gaussian Mixture Model
GRI	Global Reporting Initiative
HDBSCAN	Hierarchical Density-Based Spatial Clustering of Applications with Noise
IQR	Interquartile Range
JWT	JSON Web Token
KDD	Knowledge Discovery in Databases
KDE	Kernel Density Estimation
KPI	Key Performance Indicator
LEI	Legal Entity Identifier
LLM	Large Language Model

MAE	Mean Absolute Error
MedAE	Median Absolute Error
ML	Machine Learning
MSE	Mean Squared Error
MSCI	Morgan Stanley Capital International
PCA	Principal Component Analysis
PDF	Portable Document Format
RAG	Retrieval-Augmented Generation
RAGAS	Retrieval-Augmented Generation Assessment
RAM	Random Access Memory
REST	Representational State Transfer
RMSE	Root Mean Square Error
SAS	Statistical Analysis System
SEMMA	Sample, Explore, Modify, Model, Assess
SHA	Secure Hash Algorithm
SHAP	SHapley Additive exPlanations
SMTP	Simple Mail Transfer Protocol
SPA	Single Page Application
SVR	Support Vector Regression
VIF	Variance Inflation Factor

Introduction générale

LES critères environnementaux, sociaux et de gouvernance (ESG) sont désormais essentiels pour évaluer la performance globale des entreprises. Face aux pressions des investisseurs, la transparence sur les risques de durabilité est devenue un impératif stratégique. Dans ce contexte, les institutions financières cherchent à transformer des données hétérogènes en indicateurs fiables. Cela nécessite des méthodes de mesure objectives et standardisées, au-delà des rapports de communication.

Cependant, l'évaluation de la performance ESG se heurte à des obstacles majeurs. L'hétérogénéité des méthodologies de notation et la divergence radicale des évaluations entre agences spécialisées, documentées par [5], rendent cette mesure peu fiable et difficile à exploiter pour la prise de décision. À ces difficultés s'ajoutent des verrous techniques : les données brutes présentent une asymétrie extrême, des anomalies de saisie et un biais géographique qui faussent les comparaisons internationales. Les approches classiques (moyennes simples, pondérations arbitraires) ne parviennent pas à capturer la réelle variance du risque.

Pour surmonter ces limites, ce projet mobilise les avancées de la data science et des statistiques multivariées. Nous construisons un score propriétaire par analyse en composantes principales (ACP) hiérarchique, puis nous utilisons un modèle CatBoost pour prédire ce score. Le modèle est validé sur l'année de crise 2020 [37] et atteint une précision élevée. L'ensemble est déployé dans une plateforme analytique intégrant un tableau de bord Power BI et un assistant conversationnel fondé sur une architecture RAG (*Retrieval-Augmented Generation*).

L'objectif principal est de fournir une solution complète de notation ESG, transparente et opérationnelle. Les résultats montrent qu'un score uniforme sur $[0; 100]$ est viable, avec un R^2 de 0,9532 et une erreur moyenne (MAE) de 4,95 points. Le rapport est organisé en six chapitres :

— Chapitre 1 – Cadre général du projet

Dans ce chapitre, on présente le contexte institutionnel chez Tritux Group, la méthodologie CRISP-DM retenue et l'environnement de développement.

— **Chapitre 2 – Exploration et analyse des données**

Ce chapitre détaille l’exploration statistique, la détection des anomalies et le pré-traitement du dataset ESG, aboutissant à un jeu de données normalisé.

— **Chapitre 3 – Approche initiale : évaluation critique du clustering pour la segmentation ESG**

On y évalue les algorithmes de clustering non supervisé et l’on démontre par projection ACP la nature continue de la performance ESG.

— **Chapitre 4 – Approche avancée : du clustering au scoring continu**

Ce chapitre focalise sur la construction du score ESG propriétaire via une ACP hiérarchique, la neutralisation des biais géographiques et la validation statistique.

— **Chapitre 5 – Modélisation prédictive de la performance ESG**

On y compare huit modèles de Machine Learning, on sélectionne CatBoost et l’on interprète les prédictions grâce aux valeurs SHAP.

— **Chapitre 6 – Architecture, développement et déploiement de la plateforme ESG**

Ce chapitre présente l’architecture logicielle, l’implémentation du système RAG, le tableau de bord Power BI et le déploiement via Docker Compose.

Chapitre 1

Cadre général du projet

Introduction

L'intégration des dimensions environnementales, sociales et de gouvernance (ESG) re-définit l'analyse de risque au-delà des indicateurs financiers conventionnels. Cependant, l'hétérogénéité des sources et l'instabilité des notations extra-financières imposent le recours à des solutions de Business Intelligence pour garantir la fiabilité des décisions. L'objectif de ce projet est de concevoir une architecture analytique capable de transformer ces données complexes en un moteur de prédiction de la performance ESG. Ce chapitre établit le cadre institutionnel et méthodologique nécessaire à la réalisation de cette solution au sein de Tritux Group.

1.1 Présentation de l'organisme d'accueil

1.1.1 Identité et expertises de Tritux Group

Tritux Group est un éditeur de logiciels spécialisé dans l'ingénierie logicielle et la transformation digitale. Fort de plus de 16 années d'expérience, le groupe accompagne ses clients dans la conception et l'optimisation de systèmes d'information.



FIGURE 1.1 – Logo de l'entreprise Tritux Group

L'entreprise assure un accompagnement complet, de l'analyse des besoins à la maintenance applicative, comme détaillé dans le Tableau 1.1.

TABLE 1.1 – Domaines d'expertise de Tritux Group

Expertise	Description
Ingénierie	Développement de systèmes d'information métiers.
Conseil IT	Analyse stratégique et choix technologiques.
Intégration	Mise en œuvre de spécifications fonctionnelles.
Maintenance	Supervision et amélioration continue des systèmes.
Outsourcing	Mise à disposition de ressources spécialisées.
Support	Services de formation et d'assistance.

1.1.2 Positionnement stratégique

Tritux Group se positionne comme un partenaire dans les projets de Business Intelligence liés à la finance durable. Ses compétences en ingénierie logicielle permettent l'implémentation de solutions d'évaluation des performances ESG adaptées aux contraintes sectorielles. Les solutions proposées sont synthétisées dans le Tableau 1.2.

TABLE 1.2 – Solutions et services proposés par Tritux Group

Solution	Description
Solutions IoT	Systèmes connectés pour le milieu industriel.
Télécom	Gestion des services de télécommunication.
Solutions IT	Outils de gestion des opérations métiers.
Solutions publiques	Outils numériques pour les institutions étatiques.

1.2 Contexte ESG

1.2.1 Importance des critères extra-financiers

L'intégration des critères ESG constitue désormais un levier de performance et de résilience pour les organisations. Ces indicateurs capturent des risques auparavant ignorés, notamment l'exposition climatique et la gestion du capital humain, que les métriques comptables ne parviennent pas à isoler [15]. La pression des investisseurs impose une

adaptation des systèmes de pilotage, bien que **la mesure des performances ESG reste complexe et divergente**.

1.2.2 Problème de l’incertitude informationnelle

L’évaluation des performances ESG se heurte à une instabilité structurelle des notations. Alors que les notations financières présentent une corrélation inter-agences proche de 99 %, les évaluations ESG divergent radicalement d’une agence à l’autre pour une même entité, rendant l’information incertaine pour les décideurs [5]. Cette absence de consensus méthodologique découle de deux facteurs critiques :

- **Hétérogénéité des métriques** : les fournisseurs de données (MSCI, Sustainalytics, Refinitiv) emploient des indicateurs disparates pour évaluer un même pilier.
- **Arbitrage des pondérations** : l’importance relative accordée aux critères (E, S ou G) repose sur des modèles propriétaires et des pondérations souvent opaques.

Ce manque de fiabilité des tiers justifie le développement d’une approche plus objective, capable d’offrir une mesure de performance réelle.

1.3 Présentation du projet

1.3.1 Problématique

Dans un contexte où les critères ESG occupent une place croissante, l’identification précise des entreprises exposées aux risques extra-financiers est un défi majeur. L’hétérogénéité des sources rend nécessaire la création d’un outil capable de prédire le risque et de fournir des recommandations exploitables.

1.3.2 Objectifs

L’objectif principal est de mettre en place un système basé sur l’intelligence artificielle permettant de prédire la performance ESG à partir d’indicateurs historiques et de données extra-financières en intégrant un système de recommandation capable d’orienter les décisions vers une amélioration durable. Plus spécifiquement, le projet vise à :

- Développer un modèle de Machine Learning capable d’estimer la performance ESG de manière fiable ;
- Assurer l’interprétabilité des facteurs d’influence ;
- Concevoir un système de recommandation basé sur le système RAG (*Retrieval-Augmented Generation*) ;
- Déployer un tableau de bord Power BI interactif pour piloter les indicateurs clés.

1.3.3 Organisation et jalons

Le projet est structuré autour de cinq jalons stratégiques :

- **Jalon 1 : Prétraitement des données** — Consolidation du dataset panel, traitement des anomalies financières et création de ratios d'intensité environnementale.
- **Jalon 2 : Construction du score** — Évaluation critique des algorithmes de *clustering* et développement d'un indicateur de performance continu.
- **Jalon 3 : Modélisation** — Entraînement et évaluation des modèles prédictifs.
- **Jalon 4 : Développement de la plateforme** — Création de l'interface et intégration du système d'aide à la décision (RAG) pour exploiter les rapports de durabilité.
- **Jalon 5 : Restitution décisionnelle et Transparence** — Déploiement du tableau de bord et intégration des analyses SHAP pour garantir une IA explicable.

1.4 Cadres méthodologiques pour les projets de Data Science

La conduite d'un projet de prédiction de la performance ESG nécessite un cadre structuré. Trois approches standards sont comparées afin de sélectionner le cycle de vie le plus adapté aux contraintes de cette étude : KDD, SEMMA et CRISP-DM [58].

1.4.1 KDD

Le *Knowledge Discovery in Databases* (KDD) se définit comme un processus itératif centré sur l'extraction de motifs valides à partir de volumes de données massifs. Ses neuf étapes organisent le flux depuis la sélection des données brutes jusqu'à l'utilisation des connaissances découvertes. Bien que pionnier, ce cadre s'avère trop rigide pour des projets exigeant une réévaluation constante des objectifs métiers en fonction des premiers résultats obtenus.

1.4.2 SEMMA

Développée par l'institut SAS, la méthodologie *Sample, Explore, Modify, Model, Assess* (SEMMA) privilégie la rigueur de l'exploration statistique et de la modélisation. Ses cinq phases guident l'analyste dans la construction d'un modèle robuste par une approche cyclique et strictement technique. Toutefois, l'absence de phase de déploiement et de compréhension stratégique initiale limite son application à un audit opérationnel complet.

1.4.3 CRISP-DM

Le *Cross-Industry Standard Process for Data Mining* (CRISP-DM) propose un standard industriel structuré autour d'un cycle de vie itératif. Il articule les étapes techniques avec les contraintes organisationnelles, garantissant que les résultats servent directement les besoins du domaine. Cette flexibilité permet de naviguer efficacement entre les incertitudes des données de panel et les exigences de l'investissement responsable.

TABLE 1.3 – Comparaison des méthodologies KDD, SEMMA et CRISP-DM [58]

Critère	KDD	SEMMA	CRISP-DM
Origine	Académique	SAS Institute	Industrielle
Nombre d'étapes	9	5	6
Orientation principale	Données	Statistique	Métier
Structure du cycle	Linéaire/Itératif	Cyclique technique	Itératif global

1.4.4 Justification du choix de CRISP-DM

Le choix de CRISP-DM repose sur la nécessité d'itérations constantes entre la préparation statistique et la compréhension fine des enjeux ESG [62].

1.4.5 Application au projet ESG

Le projet suit les six phases du cycle CRISP-DM adaptées aux problématiques de notation extra-financière :

- **Compréhension métier** : analyse des enjeux de notation ESG.
- **Compréhension des données** : exploration statistique des données.
- **Préparation des données** : application des transformations et calcul des ratios.
- **Modélisation** : entraînement des modèles SVR, Random Forest, XGBoost et LightGBM et CatBoost.
- **Évaluation** : mesure de la précision via le R^2 , la RMSE et la MAE.
- **Déploiement** : intégration des scores prédictifs au sein d'une plateforme analytique.

La Figure 1.2 illustre ce cycle itératif.




FIGURE 1.2 – Processus itératif de la méthodologie CRISP-DM [62]

1.5 Environnement de développement

1.5.1 Environnement matériel

Deux machines distinctes ont été utilisées par les membres du projet.

Machine 1

TABLE 1.4 – Caractéristiques matérielles de la première machine

Composant	Caractéristiques
Modèle	ASUS Vivobook (K3605ZF)
Processeur	Intel Core i7-12700H (2.3 GHz)
Mémoire RAM	24 Go
Carte graphique	NVIDIA GeForce RTX 2050
Stockage	512 Go SSD
Système	Windows 11 Home 64 bits

Machine 2

TABLE 1.5 – Caractéristiques matérielles de la deuxième machine

Composant	Caractéristiques
Modèle	ASUS VivoBook X515EP
Processeur	Intel Core i5-1135G7 (2.40 GHz)
Mémoire RAM	24 Go
Carte graphique	NVIDIA GeForce MX330 (2 Go)
Stockage	512 Go
Système	Windows 11

1.5.2 Langages & outils de développement

- **Python** : Langage principal utilisé pour l'ensemble du pipeline data science, de la préparation des données à l'entraînement des modèles prédictifs.[51]



- **Anaconda** : Distribution Python utilisée pour la gestion des environnements virtuels et des dépendances des bibliothèques data science.[3]



- **Jupyter Notebook** : Environnement interactif utilisé pour l'exploration des données, le prototypage et la visualisation des résultats analytiques.[49]



- **Visual Studio Code** : Éditeur de code principal utilisé pour le développement du Frontend et du Backend.[43]



- **Postman** : Plateforme utilisée pour le test et la validation des endpoints de l'API REST avant leur intégration dans le Frontend.[48]




1.5.3 Frameworks & technologies

- **Flask** : Micro-framework Python utilisé pour le développement du Backend et l'exposition des API REST, notamment l'endpoint de prédiction ESG.[46]



- **React.js** : Bibliothèque JavaScript utilisée pour le développement de l'interface utilisateur, offrant une expérience dynamique et des composants réutilisables.[42]



- **PostgreSQL** : Système de gestion de bases de données relationnelles utilisé pour le stockage des données entreprises, métriques ESG et historiques de prédictions.[47]



- **Docker** : Outil de conteneurisation utilisé pour encapsuler et orchestrer les différents services de la plateforme (Frontend, Backend, base de données).[14]



1.5.4 Outils de conception & collaboration

- **draw.io** : Outil de modélisation utilisé pour la conception des diagrammes UML (cas d'utilisation, classes, séquences).[27]



- **L^AT_EX** : Système de composition utilisé pour la rédaction et la mise en page du

présent rapport.

L^AT_EX

- **GitHub** : Plateforme de gestion de versions utilisée pour le suivi du code et la collaboration tout au long du projet.[20]



- **Google Meet** : Outil de communication utilisé pour les réunions d’encadrement et le suivi du projet.[21]



Google Meet

Conclusion du chapitre

Ce chapitre a défini le cadre institutionnel du projet au sein de Tritux Group et justifié le choix de la méthodologie itérative CRISP-DM. Le chapitre suivant initie la phase technique par l’acquisition, l’exploration et le prétraitement statistique du jeu de données.

Chapitre 2

Exploration et analyse des données

Introduction

Ce chapitre détaille la phase d’exploration et analyse des données, pivot du cycle CRISP-DM. L’objectif est double : d’une part, auditer la qualité du dataset longitudinal issu de l’Institut Louis Bachelier ; d’autre part, caractériser les propriétés statistiques des indicateurs. Cette étape est cruciale pour identifier les verrous méthodologiques — notamment l’asymétrie distributionnelle et les anomalies de saisie — qui dictent la conception du pipeline de prétraitement.

2.1 Acquisition des données

L’identification d’un gisement de données robuste et multidimensionnel constitue le socle de cette étude. L’exploration initiale de dépôts publics (*Kaggle*, *Hugging Face Datasets*) et d’archives académiques a révélé les limites des jeux de données en libre accès, souvent limités à des indicateurs financiers isolés. La donnée extra-financière est privée et payante. Elle appartient à des agences spécialisées (MSCI, Refinitiv), ce qui limite son accès gratuit.

Le présent projet s’appuie finalement sur une base de données fournie par **l’Institut Louis Bachelier**. Ce dataset de panel regroupe des entreprises décrites par des variables économiques couplées à des indicateurs précis couvrant les trois piliers de la durabilité (Environnement, Social, Gouvernance). Ces données constituent la base des analyses réalisées dans la suite de ce travail.

2.2 Description du dataset

2.2.1 Structure des données

Le dataset est un panel organisé selon un index hiérarchique (`company_id`, `year`), combinant une dimension transversale (comparaison entre entreprises) et une dimension temporelle (évolution sur trois années). L’unicité de chaque couple (`company_id`, `year`) a été vérifiée : aucun doublon n’est présent.

2.2.2 Période et taille du dataset

L’étude couvre les exercices 2018 à 2020. Ce qui présente l’avantage d’offrir un panel parfaitement équilibré : chaque entreprise apparaît pour l’intégralité des trois années. Cette caractéristique facilite les comparaisons intertemporelles et simplifie le traitement des données manquantes.

L’échantillon final comprend 13 518 entreprises uniques, et un volume total de 40 554 observations (firm-year).

2.2.3 Types de variables

Le dataset intègre 25 colonnes, réparties en trois grandes familles : Variables d’identification Indicateurs financiers et Indicateurs ESG couvrant les trois piliers de la durabilité : Environnement, Social et Gouvernance.

2.2.4 Qualité des données

Les contrôles préliminaires ont confirmé l’absence de valeurs manquantes sur l’ensemble des variables numériques, ce qui témoigne de la qualité du travail de consolidation réalisé par l’Institut Louis Bachelier. Seules quelques variables textuelles (description d’activité, code ISIN) présentent un faible taux de lacunes, sans incidence sur les analyses quantitatives.

2.3 Taxonomie et Dictionnaire des Variables

Nous présentons la sélection des variables qui a été pensée pour couvrir les trois piliers de la durabilité – Environnemental (E), Social (S) et de Gouvernance (G) – ainsi que des indicateurs financiers servant de variables de contrôle. Le tableau 2.1 présente les 25 colonnes du dataset, en précisant pour chacune sa catégorie, sa définition, son unité de mesure et son intérêt dans l’analyse.

TABLE 2.1 – Dictionnaire des variables du panel ESG

Nom de la variable	Description & Unité	Utilité dans l'analyse
Identification		
company_id	Identifiant unique attribué à chaque entreprise (chaîne de caractères)	Garantit la traçabilité et permet la construction de l'index hiérarchique
year	Année de l'observation (2018, 2019, 2020)	Introduit la dimension temporelle du panel
company_name	Dénomination sociale complète de l'entreprise	Identification nominale, utilisée pour la vérification manuelle
ticker	Code boursier (ex. OM:XANO B)	Facilite le lien avec des bases de données financières externes
LEI	<i>Legal Entity Identifier</i> — code alphanumérique normalisé (ISO 17442)	Identifiant unique et pérenne des personnes morales
isin	<i>International Securities Identification Number</i> — code d'identification des titres financiers	Permet un appariement précis avec les bases de données de marché
Business Desc.	Description textuelle de l'activité principale de l'entreprise	Fournit un contexte sectoriel qualitatif
region	Région géographique du siège social (ex. Europe, Asia/Pacific)	Variable catégorielle utilisée pour des analyses de segmentation géographique
hq_country	Pays du siège social	Permet des regroupements par pays
primary_industry	Secteur d'activité principal selon la classification GICS (ex. <i>Industrial Machinery</i>)	Essentielle pour contrôler les effets sectoriels et pour l'interprétation des clusters
Variables financières		

Nom de la variable	Description & Unité	Utilité dans l'analyse
market_cap	Capitalisation boursière en fin d'exercice (en millions d'unités monétaires). Min = 36,8 ; max = 2,25 M	Indicateur de la taille de l'entreprise ; permet de normaliser les ratios d'intensité ESG
employees	Nombre total de salariés (en unités). Min = 1 ; max = 2,3 M	Mesure la dimension de la main-d'œuvre, utilisée comme variable de contrôle et pour calculer des indicateurs par employé
revenue	Chiffre d'affaires annuel (en millions d'unités monétaires). Min = -13 944 ; max = 46 984	Reflète la performance économique
Pilier Environnemental (E)		
scope_1	Émissions directes de GES (tCO ₂ eq). Min = 0 ; max = 554 M	Mesure l'empreinte carbone directement générée par les sources détenues ou contrôlées par l'entreprise
scope_2	Émissions indirectes liées à la consommation d'énergie (tCO ₂ eq). Min = 0 ; max = 406 M	Reflète l'impact de la production d'énergie achetée et consommée
scope_3	Autres émissions indirectes — chaîne de valeur amont et aval (tCO ₂ eq). Min = 0 ; max = 16,8 Md	Indicateur clé de la responsabilité élargie, souvent très concentré sur quelques grandes entreprises
energy_consumption	Consommation totale d'énergie (MWh). Min = 0 ; max = 81,7 Md	Proxy de l'intensité énergétique et de la dépendance aux énergies fossiles
waste_production	Volume de déchets produits (en tonnes). Min = 0 ; max = 28 Md	Mesure l'impact sur l'environnement local et la gestion des ressources
waste_recycling	Volume de déchets recyclés (en tonnes). Min = 0 ; max = 84 M	Indique l'engagement dans l'économie circulaire

Nom de la variable	Description & Unité	Utilité dans l'analyse
water_consumption	Volume d'eau consommé (m ³). Min = 0 ; max = 69 Md	Pression sur la ressource en eau, enjeu stratégique pour les industries à forte intensité hydrique
water_withdrawal	Volume d'eau prélevé (m ³). Min = 0 ; max = 91,6 Md	Distingue le prélèvement de la consommation et renseigne sur les pressions locales
Pilier Social (S)		
hours_of_training	Nombre total d'heures de formation dispensées aux salariés. Min = 0 ; max = 148 M	Proxy de l'investissement dans le capital humain et de la politique de développement des compétences
Pilier Gouvernance (G)		
independent_board_members_percentage	Proportion d'administrateurs indépendants au sein du conseil (en %). Min = 0 ; max = 100	Indicateur de la qualité de la gouvernance et de l'équilibre des pouvoirs
legal_costs_paid_for_controversies	Coûts juridiques supportés à la suite de controverses (en unités monétaires). Min = 0 ; max = 14 830	Révèle l'exposition aux risques extra-financiers et la capacité à gérer les litiges
ceo_compensation	Rémunération totale du directeur général (en unités monétaires). Min = 9 768 ; max = 5,93 Md	Permet d'apprécier les pratiques de rémunération et l'alignement avec la performance long terme

Note : Période couverte : 2018–2020. Les unités monétaires sont en millions sauf mention contraire.

L'hétérogénéité des unités et des échelles de grandeur impose une standardisation rigoureuse. Sans transformation préalable, les variables aux ordres de grandeur les plus élevés biaiserait les calculs de distance des algorithmes de clustering.

2.4 Analyse exploratoire des données (EDA)

L'analyse exploratoire vise à valider la fiabilité des observations avant modélisation. Cette étape a permis d'identifier des verrous critiques orientant la stratégie de préparation des données.

2.4.1 Asymétrie distributionnelle

L'examen des histogrammes de la Figure 2.1 révèle une **asymétrie positive extrême** sur la quasi-totalité des indicateurs. Afin de rendre visibles les observations situées en queue de distribution, les fréquences sont représentées sur une échelle logarithmique.




FIGURE 2.1 – Distributions des variables (échelle semi-logarithmique) : mise en évidence de la forte asymétrie positive initiale

La majorité des entreprises présentent des impacts environnementaux proches de zéro, tandis qu'une infime minorité concentre l'essentiel de la variance. Cette asymétrie, marquée par un *skewness* supérieur à 100 pour le Scope 3 (moyenne de 3,6 Mt contre une médiane de 37 581 t), interdit l'usage brut d'un clustering fondé sur la distance euclidienne, sous peine de voir les valeurs extrêmes écraser la population globale. Seule la variable `independent_board_members_percentage` affiche une distribution quasi-symétrique.

2.4.2 Anomalies et valeurs suspectes

Deux anomalies majeures ont été isolées :

- **Anomalie de la rémunération des dirigeants** : sept observations affichent une valeur identique et aberrante de 2034 700 000€ dans la variable `ceo_compensation`. L'écart au 99^e percentile confirme une erreur de saisie systématique. Non traitée, cette anomalie fausserait le calcul des centroïdes de clusters.
- **Revenus négatifs** : L'analyse identifie 50 observations affichant un chiffre d'affaires négatif. Les Figures 2.2 et 2.3 permettent d'en caractériser la nature.




FIGURE 2.2 – Répartition sectorielle des entreprises à revenu négatif.




FIGURE 2.3 – Répartition temporelle des observations à revenu négatif.

L'examen de ces figures montre que ces revenus négatifs sont quasi exclusifs au secteur financier (*Diversified Banks*, *REITs*) et répartis de manière stable sur la période 2018–2020. Il s'agit donc de réalités comptables récurrentes et non d'erreurs de collecte. Sur le plan méthodologique,

ces valeurs interdisent l'application d'une transformation logarithmique simple pour le calcul des ratios d'intensité, imposant un traitement spécifique.

2.5 Analyse des corrélations entre variables

Compte tenu de l'asymétrie extrême et de la présence d'outliers identifiés précédemment, nous privilégions le coefficient de corrélation de Spearman au détriment de celui de Pearson. Ce choix permet de mesurer de manière plus robuste les relations entre variables, sans supposer la normalité des distributions ni la linéarité des liaisons.[24] La figure 2.4 présente cette matrice sous forme de *heatmap*.

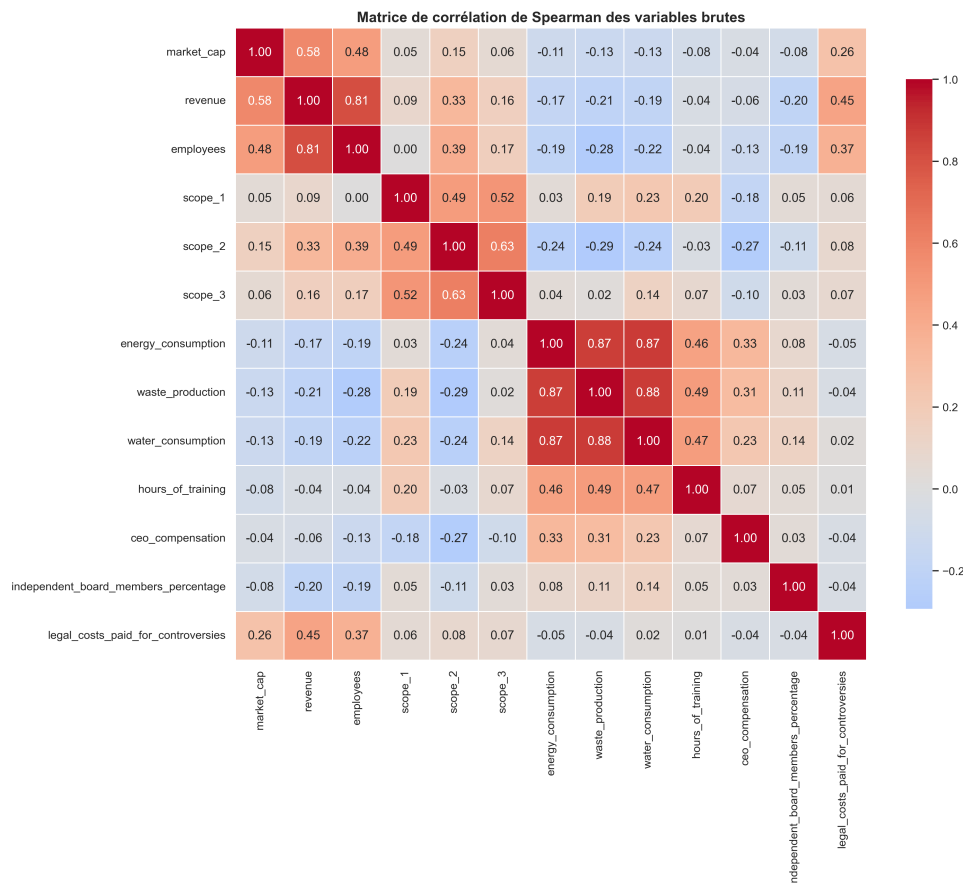


FIGURE 2.4 – Matrice de corrélation de Spearman des variables numériques brutes

L'analyse de la matrice de corrélation révèle les tendances suivantes :

- **Redondances opérationnelles** : Une corrélation très forte est observée entre le chiffre d'affaires (**revenue**) et les effectifs (**employees**), avec un coefficient de 0,814. Cette colinéarité prévisible confirme que ces deux variables capturent une dimension identique (la taille de l'entreprise).
- **Émergence du bloc environnemental** : La production de déchets, la consommation d'eau et la consommation d'énergie sont structurellement liées (corrélations > 0,86). Ce bloc cohérent est dicté par les processus industriels, ce qui justifiera leur traitement conjoint dans le pipeline de prétraitement.

2.6 Prétraitement et raffinement des données ESG

Les asymétries extrêmes, anomalies de saisie et revenus négatifs identifiés dans les sections précédentes rendent les données brutes impropres à une modélisation directe. Le pipeline suivant les traite en six étapes séquentielles (Figure 2.5).




FIGURE 2.5 – Pipeline de prétraitement des données ESG

2.6.1 Nettoyage et validation

Les variables catégorielles ont été converties au format `category` pour optimiser la mémoire. Un indicateur binaire `revenue_negative_flag` a été créé pour signaler les 50 observations à chiffre d'affaires négatif, permettant aux modèles ultérieurs de les identifier sans biaiser les calculs de ratios d'intensité.

2.6.2 Atténuation des valeurs extrêmes

Les sept valeurs aberrantes de `ceo_compensation` (2,03 milliards d'euros) ont été traitées par winsorisation : les valeurs dépassant le 99^e percentile sont écrêtées à ce seuil (29,2 millions d'euros). Cette approche limite l'influence des points aberrants sans supprimer les observations [40].

2.6.3 Transformation logarithmique et traitement de la skewness résiduelle

Les indicateurs ESG couvrent plusieurs ordres de grandeur (de quelques tonnes à des millions de tonnes de CO_2), ce qui rend la variance instable. Pour stabiliser cette dispersion et réduire l'asymétrie, une transformation $f(x) = \log(1+x)$ est appliquée. Le décalage de +1 évite l'indéfinition de $\log(0)$ pour les variables pouvant être nulles.

Cette transformation est sélective :

- Variables financières (`revenue`, `market_cap`) et environnementales (`scopes`, `energy`, `waste`, `water`) – fortement asymétriques.
- Variables en pourcentage (`independent_board_members_percentage`) – exclues, car le log déformerait leur distribution sans bénéfice.
- Variables binaires – conservées en l'état.

Selon le critère de Bulmer [9], une skewness résiduelle supérieure à 1,5 en valeur absolue signale une asymétrie substantielle. Pour `log_revenue` et `log_hours_of_training` dépassant ce seuil, une winsorisation complémentaire au top 1 % limite l'influence des queues de distribution [40].

2.6.4 Calculs, stabilisation et normalisation des indicateurs d'intensité

L'efficacité environnementale et sociale a été modélisée par la création de ratios d'intensité calculés dans l'espace logarithmique par soustraction : $\log(A) - \log(B) = \log(A/B)$. Afin de résoudre l'indéfinition mathématique pour les 50 observations où le revenu (B) est négatif, le calcul utilise une translation (décalage basé sur la valeur minimale du dataset). La présence du flag `revenue_negative_flag` permet de signaler ces cas particuliers lors de la modélisation.

Exemples d'indicateurs :

- **Intensités environnementales** (Scopes 1, 2, 3, énergie, déchets, eau par euro de chiffre d'affaires) : elles reflètent l'empreinte écologique par unité de valeur produite, indicateur clé d'efficience.
- **Intensité de formation** (heures de formation par employé) : mesure l'effort d'investissement en capital humain par salarié.
- **Productivité** (chiffre d'affaires par employé) : variable de contrôle liant performance financière et impact ESG.

Bien que calculés dans l'espace logarithmique pour stabiliser les écarts, ces ratios ont nécessité une winsorisation à 1%, évitant que des entreprises aux revenus extrêmement faibles ne génèrent des valeurs artificiellement gigantesques[40].

2.6.5 Détection des outliers multivariés

La distance de Mahalanobis mesure l'écart d'une observation par rapport au centre du nuage de points, en tenant compte des corrélations entre variables. Contrairement au Z-score qui traite chaque variable séparément, elle détecte les anomalies dans l'espace multidimensionnel.

Ce calcul nécessite d'inverser la matrice de covariance Σ . L'inversion n'est possible que si $\det(\Sigma) \neq 0$, ce qui est garanti par l'absence de colinéarité parfaite entre variables — condition vérifiée grâce aux transformations de la section 2.6.3.

La distance est calculée selon :

$$D_M(x) = \sqrt{(x - \mu)^T \Sigma^{-1} (x - \mu)}$$

où μ est le vecteur des moyennes et Σ la matrice de covariance des variables.

Une observation est identifiée comme anomalie si D_M^2 dépasse le quantile à 97,5 % de la loi du χ^2 à p degrés de liberté, où p est le nombre de variables incluses ($p = 15$ pour les variables transformées, $p = 23$ en ajoutant les ratios d'intensité) [39].

Comme l'illustre la Figure 2.6, l'ajout des ratios fait passer la détection d'une logique comparable (revenus négatifs) à une logique métier : les entreprises signalées sont celles dont le comportement environnemental est réellement atypique par rapport à leur secteur.




FIGURE 2.6 – Impact de l’introduction des ratios d’intensité sur la détection des anomalies multidimensionnelles

2.6.6 Décision finale concernant les outliers multivariés

L’audit des 35 observations identifiées comme outliers après introduction des ratios montre qu’elles reflètent des profils industriels atypiques (secteurs hyper-polluants) plutôt que des erreurs de mesure. Pour mesurer l’impact de ces 35 points, nous avons comparé le centre de gravité des données avec et sans eux. Le déplacement constaté n’est que de 0,07 %, ce qui est dérisoire face au seuil de 5 % marquant une influence réelle [13]. Leur présence ne déforme donc pas la structure globale de l’échantillon. Par conséquent, ces observations sont conservées pour garantir la richesse informationnelle du dataset.

2.6.7 Standardisation robuste

La dernière étape du pipeline consiste à ramener toutes les variables transformées à une échelle commune. Une standardisation classique (Z-score) étant sensible aux points atypiques conservés, nous utilisons le **RobustScaler**. Chaque variable est centrée par sa médiane et divisée par son écart interquartile (IQR) selon la formule :

$$x_i^{\text{scaled}} = \frac{x_i - \text{médiane}(x)}{Q_3(x) - Q_1(x)}$$

Cette méthode garantit que toutes les dimensions contribuent équitablement aux calculs de distance sans qu’une variable ne domine par son unité de mesure [40]. Le jeu de données est désormais prêt pour la modélisation prédictive.

2.7 Validation finale : Audit du dataset traité

L’exécution intégrale du pipeline de prétraitement nécessite une phase d’audit final afin de vérifier que les problèmes critiques identifiés dans les données brutes ont été corrigés. Cette

validation garantit que le jeu de données est statistiquement sain, cohérent et apte à supporter les algorithmes de clustering du chapitre suivant.

2.7.1 Validation de la correction du biais de rémunération

L'efficacité de la winsorisation appliquée à la variable `ceo_compensation` est confirmée par l'analyse de sa distribution post-traitement. Comme l'illustre la Figure 2.7, le pic anormal initial (lié à l'erreur systématique de 2,03 milliards d'euros) a été neutralisé. Le remplacement de ces valeurs par le 99^e percentile (29,2 millions d'euros) restaure une distribution de queue supérieure cohérente avec la réalité économique des dirigeants de grands groupes, sans créer de rupture artificielle dans la variance de l'échantillon.




FIGURE 2.7 – Comparaison de la distribution de la rémunération CEO avant et après winsorisation

2.7.2 Vérification de la distribution des variables transformées

L'impact des transformations sur les variables numériques a été quantifié via le calcul des coefficients d'asymétrie.

Conformément au critère de Bulmer [9], la quasi-totalité des variables présente désormais une asymétrie inférieure à $|1,5|$, confirmant la symétrisation des distributions. Les variables `revenue` et `hours_of_training`, initialement critiques, affichent une réduction de skewness supérieure à 70% après traitement. Par ailleurs, la variable `independent_board_members_percentage`, reste inchangée, ce qui est cohérent avec sa distribution initialement symétrique. La Figure 2.8 présente les histogrammes finaux, où la superposition des moyennes et médianes confirmant la symétrisation des variables.




FIGURE 2.8 – Distributions finales des variables après pipeline de prétraitement

2.7.3 Validation de la structure de corrélation

La comparaison entre la matrice de Spearman initiale et les corrélations après transformation (Figure 2.9) permet de vérifier que les transformations n'ont pas altéré les relations ESG-financières.

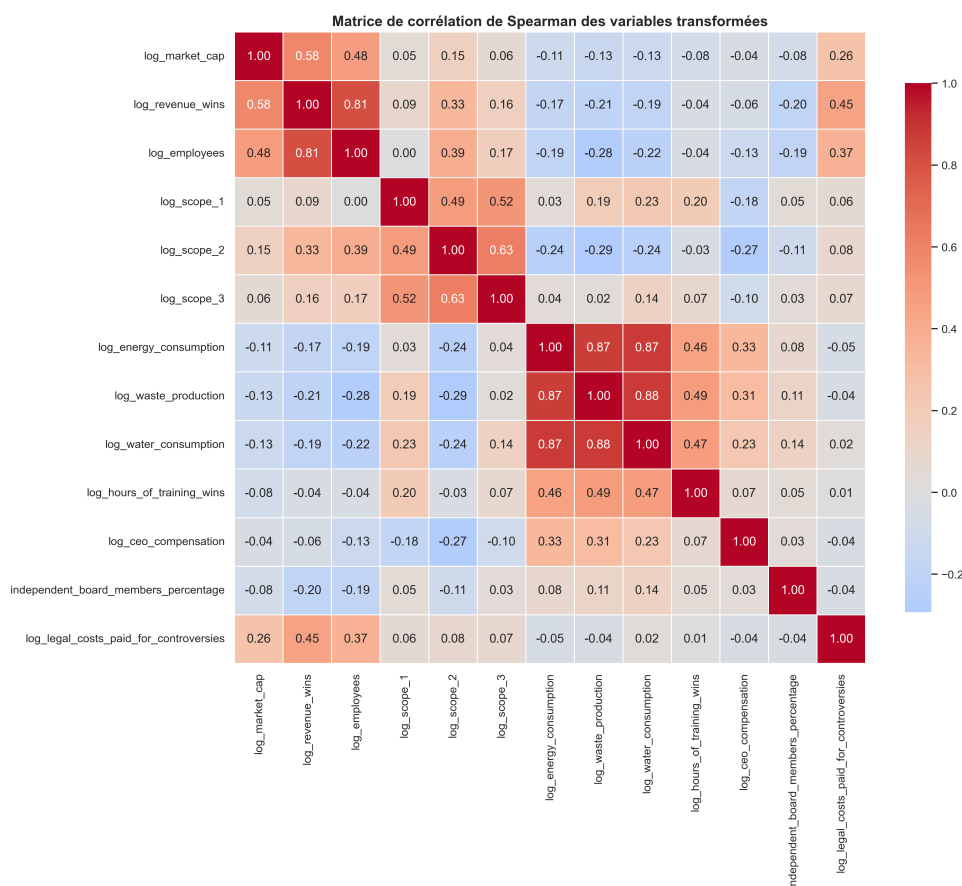


FIGURE 2.9 – Matrice de corrélation après prétraitement

- **Validation de la redondance taille** : La corrélation entre les effectifs et le chiffre d'affaires reste rigoureusement identique, confirmant la préservation de la structure économique du dataset.
- **Validation du bloc environnemental** : Les corrélations très fortes entre les trois flux de consommation (déchets, eau, énergie) sont préservées, démontrant que la cohérence industrielle du trio n'a pas été dénaturée.

L'analyse des corrélations confirme l'absence de biais artificiel et la neutralité statistique du pipeline, renforcée par la normalisation des échelles (RobustScaler).

Conclusion du chapitre

L'ensemble des étapes de ce chapitre, de l'acquisition à la validation finale, a transformé un gisement de données brutes en un dataset de panel équilibré et statistiquement robuste. La levée des verrous d'asymétrie, d'influence des points atypiques et de colinéarité permet d'engager la phase de modélisation non supervisée sur des bases saines.

Chapitre 3

Approche initiale : Évaluation critique du clustering pour la segmentation ESG

Introduction

Ce chapitre détaille le premier cycle expérimental visant à segmenter un panel de 40 554 observations (13 518 entreprises sur la période 2018–2020). En l’absence de variable cible, une approche d’apprentissage non supervisé a été privilégiée pour identifier des profils comportementaux homogènes au-delà des notations ESG conventionnelles [23, 5]. Le cadre technique déploie trois algorithmes de *clustering* évalués selon trois indicateurs de performance. Cette analyse expose les limites de l’approche discrète face à la nature réelle des données ESG.

3.1 Algorithmes et métriques d’évaluation

3.1.1 Choix des modèles

K-Means

Le premier modèle étudié est le K-Means.

- **Sensibilité aux valeurs extrêmes** : L’algorithme minimise l’inertie intra-classe calculée à partir des distances euclidiennes au carré [57] :

$$\sum_{i=1}^n \min_{\mu_j \in C} (\|x_i - \mu_j\|^2) \quad (3.1)$$

La conservation des valeurs extrêmes peut déplacer le centre d’un groupe et fausser la position du *cluster*.

- **Centroïde non représentatif** : Le centre calculé est une moyenne arithmétique ne correspondant souvent à aucune observation du dataset.

- **Séparation artificielle** : Le K-Means impose une structure sphérique [23], forçant un découpage au sein d’une distribution continue.

GMM (Gaussian Mixture Model)

Le passage au GMM répond au besoin de dépasser la rigidité géométrique du K-Means.

- **Appartenance probabiliste** : Contrairement au K-Means, le GMM attribue à chaque observation une probabilité d’appartenance à chaque *cluster*. Il modélise la densité comme une combinaison de lois normales multivariées $\mathcal{N}(x \mid \mu_k, \Sigma_k)$ [53] :

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k) \quad (3.2)$$

où π_k est le poids du *cluster* k , μ_k le vecteur moyenne et Σ_k la matrice de covariance. La forme ellipsoïdale des *clusters* découle de Σ_k , capturant les corrélations inter-variables absentes du K-Means.

- **Limites** : Le GMM peine à isoler des composantes disjointes et force chaque observation à intégrer un segment, même en présence de profils atypiques isolés [56].

HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise)

Le passage à HDBSCAN identifie des zones de forte densité.

- **Valeur ajoutée** : Il identifie des structures de densité variable organisées hiérarchiquement. Il repère des groupes de formes complexes et de densités variables.
- **Filtrage du bruit structurel** : HDBSCAN possède la capacité de rejeter des observations et de les étiqueter comme bruit.

L’algorithme repose sur la distance de mutuelle atteignabilité :

$$d_{\text{mreach},k}(a, b) = \max(\text{core}_k(a), \text{core}_k(b), d(a, b)) \quad (3.3)$$

où $\text{core}_k(x)$ est la distance au k -ième plus proche voisin de x et $d(a, b)$ la distance euclidienne [10].

3.1.2 Métriques d’évaluation

Pour évaluer la qualité des partitions, trois indicateurs sont utilisés :

Score de Silhouette

Mesure le compromis entre cohésion intra-classe $a(i)$ (distance moyenne aux membres du même groupe) et séparation inter-classe $b(i)$ (distance moyenne au groupe le plus proche), selon la formule :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (3.4)$$

Un score proche de 1 indique une partition nette [31].

Adjusted Rand Index (ARI)

Mesure la concordance entre deux partitions indépendamment du nombre de classes, en corrigeant l'accord aléatoire [25]. Son usage inter-modèles est justifié pour quantifier la stabilité des décisions de *clustering*.

Critères BIC et AIC

Le *Bayesian Information Criterion* (BIC) et l'*Akaike Information Criterion* (AIC) permettent de sélectionner le nombre optimal de composantes dans le GMM :

$$\text{BIC} = -2\ln(\hat{L}) + k \ln(n), \quad \text{AIC} = -2\ln(\hat{L}) + 2k \quad (3.5)$$

où $\hat{L}$ est la vraisemblance maximisée, k le nombre de paramètres et n le nombre d'observations [1, 55].

3.1.3 Optimisation des hyperparamètres

Trois métriques sont analysées sur une plage de $k = 2$ à 10.

L'ARI (Figure 3.1) atteint son maximum à $k = 7$ (0,39), indiquant la concordance maximale entre K-Means et GMM.




FIGURE 3.1 – Évolution de l'Adjusted Rand Index (ARI) entre K-Means et GMM en fonction de k

Le score de Silhouette pour les algorithmes K-Means et GMM (Figure 3.2) se stabilise à partir de $k = 7$ sans gain au-delà, confirmant qu'une fragmentation accrue n'améliore pas la cohésion des groupes.




FIGURE 3.2 – Évolution du score de Silhouette pour K-Means et GMM en fonction de k

Les critères BIC et AIC (Figure 3.3) décroissent de façon monotone sans minimum identifiable, les rendant non discriminants pour la sélection de k . La valeur $k = 7$ est donc retenue, portée par le maximum de l'ARI et le coude de stabilisation de la Silhouette.




FIGURE 3.3 – Évolution des critères BIC et AIC pour le modèle GMM en fonction de k

3.2 Évaluation : analyse des performances du clustering

3.2.1 Résultats quantitatifs

Les performances détaillées sont synthétisées dans le Tableau 3.1.

TABLE 3.1 – Évolution du score de Silhouette et de l'ARI selon k (K-Means et GMM)

k	Silhouette (K-Means)	Silhouette (GMM)	ARI
2	0,43	0,14	−0,06
3	0,20	0,17	0,02
4	0,23	0,11	0,12
5	0,25	0,12	0,30
6	0,27	0,10	0,21
7	0,28	0,14	0,39
8	0,28	0,13	0,26
9	0,27	0,14	0,37
10	0,29	0,15	0,34

HDBSCAN détecte 13 *clusters* mais rejette 38,68 % des observations comme bruit (15 686 points). Sur les observations non rejetées, le score de Silhouette atteint 0,449, sans pour autant indiquer une structure compacte exploitable.

3.2.2 Résultats qualitatifs

La confrontation des trois algorithmes, illustrée par la Figure 3.4 et le Tableau 3.2, révèle une instabilité structurelle majeure des partitions.

TABLE 3.2 – Répartition des observations par niveau de consensus algorithmique.

Niveau de consensus	Nombre d'observations	Proportion (%)
Accord total	3 808	9,4 %
Accord partiel	17 780	43,8 %
Bruit structurel	18 966	46,8 %
Total	40 554	100,0 %




FIGURE 3.4 – Niveau de consensus entre les trois algorithmes de *clustering* ($k = 7$).

Seulement 9,4 % des observations sont classées de manière identique par les trois modèles, ce qui prouve que les groupes identifiés dépendent du paradigme mathématique de chaque algorithme plutôt que de structures naturelles. Par ailleurs, près de la moitié du dataset (46,8 %) est classée en bruit ou fait l’objet d’un désaccord total. L’incapacité de HDBSCAN et du GMM à s’accorder sur la majorité des données confirme l’absence de frontières nettes entre les profils ESG des entreprises.

3.3 Discussion : le continuum ESG

L’incapacité des algorithmes à stabiliser des groupes cohérents ne permet pas de distinguer si cet échec provient d’une mauvaise configuration des modèles ou de la géométrie intrinsèque des données. Pour poser ce diagnostic structurel, l’Analyse en Composantes Principales (ACP) est utilisée afin de projeter l’espace multidimensionnel dans un plan bi-dimensionnel. L’objectif est d’inspecter visuellement la continuité de l’espace ou l’existence de ruptures entre les profils d’entreprises.

3.3.1 Visualisation spatiale et limites de la classification

Le choix de retenir les deux premières composantes principales (PC1 et PC2) est dicté par un impératif de lisibilité graphique. Bien que cette réduction ne capture que (51,6 %) de l’information totale, elle suffit à révéler la tendance globale de la distribution spatiale du dataset.

La Figure 3.5 projette les 40 554 observations en colorant chaque point selon sa classe de consensus algorithmique.




FIGURE 3.5 – Projection ACP des observations ESG par classe de consensus (PC1 : 35,2 %, PC2 : 16,4 % de variance expliquée).

Les observations se superposent dans une structure unique de type « nuage » sans zones de densité isolées ni espaces vides permettant de justifier des frontières de catégories. Même les cas d'accord total s'imbriquent au cœur de la masse globale, confirmant que le consensus entre algorithmes reflète une densité centrale et non une séparation physique. Imposer une segmentation sur ce continuum reviendrait à introduire des frontières arbitraires sans discontinuité statistique dans les données [5].

3.3.2 La nature continue de la performance ESG

L'apport majeur de cette analyse est de démontrer que la performance ESG ne se prête pas à une nomenclature en « familles » étanches. Les entreprises évoluent sur un spectre de risque multidimensionnel continu. Ce résultat impose de remplacer la classification par étiquettes par une logique de **scoring** sur échelle continue. Une notation par classes discrètes masquerait la variance réelle et la position relative des entités.

Conclusion du chapitre

Les trois algorithmes convergent vers un constat identique : aucun ne produit de groupes distincts. Le score de Silhouette ne dépasse pas 0,28 pour $k \geq 3$, l'ARI plafonne à 0,39 à $k = 7$, et HDBSCAN rejette 38,68 % des observations comme bruit. La projection ACP confirme visuellement l'absence de frontières naturelles : les profils ESG forment un continuum, non une partition discrète. Ce résultat est cohérent avec les travaux de Berg et al. [5], qui montrent que la performance ESG est continue et ne se prête pas à une catégorisation discrète. Ces résultats invalident l'approche par *clustering* et motivent le recours à un score continu développé au chapitre 4.

Chapitre 4

Approche avancée : du clustering au scoring continu

Introduction

Suite à l'absence de structure de groupes isolés démontrée au Chapitre 3, ce second cycle expérimental reformule l'objectif : passer d'une classification discrète à une mesure de performance continue. Nous analysons ici l'échec des méthodes d'agrégation classiques, l'impact du biais géographique sur l'équité du score, et la nécessité de construire un indicateur synthétique capable de refléter la variance réelle des données sans la subjectivité des agences de notation.

4.1 Redéfinition de la compréhension métier : du clustering au scoring

La transition vers le scoring continu permet de mieux respecter la nature des données ESG, qui forment un continuum de risque plutôt que des catégories étanches.

4.1.1 Pivot de l'objectif : de la « catégorie » à la « performance relative »

La littérature sur le « rating disagreement » [5] souligne que les agences (MSCI, Sustainalytics, Asset4) divergent radicalement dans leurs évaluations. Puisque les experts ne s'entendent sur aucune frontière stable, notre objectif devient de définir une méthodologie de scoring capable de situer chaque observation sur un continuum de 0 à 100.

4.1.2 Le problème du biais géographique

Un obstacle majeur au scoring équitable réside dans le pays d'origine. La Figure 4.1 présente l'intensité carbone moyenne par pays. Elle révèle des fractures structurelles qui dépendent sou-

vent du mix énergétique national ou du cadre réglementaire local plutôt que de la seule gestion de l'entreprise.

Intensité carbone moyenne (Scope 1 / CA) par pays




FIGURE 4.1 – Intensité carbone moyenne (Scope 1 / CA) par pays

L'analyse montre qu'utiliser un score brut reviendrait à pénaliser une entreprise pour son environnement macroéconomique. Le pays doit donc être traité comme une variable de variance à neutraliser pour isoler la performance opérationnelle intrinsèque. Cette approche vise à isoler la performance opérationnelle intrinsèque de l'entreprise, indépendamment de son cadre réglementaire national. Il convient de noter que ces disparités géographiques peuvent aussi refléter des différences institutionnelles réelles [36].

4.2 Diagnostic des échecs du scoring traditionnel

Avant d'utiliser des méthodes avancées, nous testons deux approches d'agrégation simples pour illustrer leurs limites statistiques.

4.2.1 Approche 1 : La moyenne simple

La méthode la plus directe consiste à calculer la moyenne arithmétique des indicateurs d'intensité standardisés :

$$Score_i = \frac{1}{n} \sum_{j=1}^n x_{i,j} \quad (4.1)$$

où $x_{i,j}$ est la valeur de l'indicateur j pour l'entreprise i , et n le nombre total d'indicateurs.

- **Limite fondamentale** : cette approche traite toutes les variables comme indépendantes. Elle ignore les fortes corrélations (ex. : bloc énergie-eau-déchets) identifiées au Chapitre 2, ce qui conduit à sur-pondérer certains facteurs redondants.

4.2.2 Approche 2 : La pondération arbitraire

Cette approche attribue des poids fixes aux trois piliers (E, S, G) selon une intuition métier :

$$Score_i = w_E \cdot \bar{E}_i + w_S \cdot \bar{S}_i + w_G \cdot \bar{G}_i \quad (4.2)$$

où w_E , w_S et w_G sont les poids attribués aux piliers, et $\bar{E}_i$, $\bar{S}_i$, $\bar{G}_i$ les moyennes des indicateurs de chaque pilier pour l'entreprise i , avec $w_E + w_S + w_G = 1$.

- **Limite fondamentale** : le choix des coefficients est subjectif. Cette méthode reproduit l'incohérence des agences de notation au lieu de laisser les données « parler » et révéler l'importance réelle de chaque variable.

4.2.3 Échec commun : écrasement de la variance

La Figure 4.2 compare la distribution des scores obtenus par ces deux méthodes. Le graphique de densité (KDE) révèle un défaut majeur : l'écrasement de la variance.




FIGURE 4.2 – Distribution (KDE) des scores obtenue par moyenne simple et pondération arbitraire : mise en évidence de la faible dispersion

En additionnant les variables sans corriger leurs liaisons statistiques, ces méthodes produisent des scores concentrés autour de la moyenne. Cette faible dispersion rend le score inexploitable pour le Machine Learning, car il devient impossible de distinguer nettement les entreprises performantes des profils à risque.

4.3 Solution : L'Analyse en Composantes Principales (ACP) Hiérarchique

Face aux limites des méthodes classiques de scoring ESG – subjectivité des pondérations, biais géographique – nous avons développé une approche fondée sur une ACP hiérarchique à deux niveaux.

4.3.1 Nettoyage des colinéarités : une étape préalable indispensable

Avant d'appliquer l'ACP, nous devons supprimer les redondances entre variables. Selon [45], une colinéarité excessive gonfle artificiellement la variance des poids, rendant le score instable. Pour pallier ce biais, nous avons appliqué une réduction de dimension en deux étapes :

- **Filtrage par corrélation** ($|r| > 0,8$) : élimine les paires de variables dont la corrélation en valeur absolue dépasse ce seuil, qu'elle soit positive ou négative.
- **VIF (*Variance Inflation Factor*) itératif** : mesure à quel point une variable est expliquée par les autres variables du même groupe. Nous avons fixé un seuil de $VIF < 10$, limite critique identifiée par [22] pour garantir l'indépendance statistique.

Cette méthode a permis de condenser le pilier E (12 variables à 4) et le pilier S (4 variables à 2), tandis que le pilier G est resté intact (4 variables). Cette sélection garantit que chaque variable apporte une information unique.

4.3.2 ACP de niveau 1 : synthétiser chaque pilier

L'enjeu est de transformer les indicateurs techniques en trois scores simplifiés, un pour chaque pilier (E, S et G). Pour ce faire, nous utilisons une ACP de Niveau 1. Contrairement aux agences de notation qui fixent des coefficients de manière arbitraire, l'ACP laisse les données « parler ». Selon [29], cette méthode permet d'extraire les axes de variance maximale : le poids de chaque variable est dicté par sa capacité réelle à différencier les observations.

Le Tableau 4.1 retrace le passage des données brutes vers les scores synthétiques.

TABLE 4.1 – Synthèse de l'ACP de Niveau 1 par pilier ESG.

Pilier	Variables Initiales	Après Nettoyage (VIF/Corr)	Synthèse ACP (Comp.)	Information Conservée	Vecteur Principal (Loading)
Environnement (E)	12	4	3	92,57 %	Émissions CO ₂ (Scope 1 & 3)
Social (S)	4	2	2	100,00 %	Capital Humain / Formation
Gouvernance (G)	4	4	1	83,78 %	Structure de Revenus & Cap. Boursière




FIGURE 4.3 – Corrélations entre les scores des piliers ESG.

La robustesse de cette étape est validée par la faible corrélation entre les scores obtenus (Figure 4.3). Cela prouve que chaque pilier mesure une dimension unique du risque ESG.

4.3.3 ACP de niveau 2 : la pondération naturelle

L'étape finale consiste à agréger les scores E, S et G en un Score ESG Global. Nous appliquons une ACP de second niveau sur des données préalablement standardisées. La Figure 4.4 présente les poids extraits de la première composante principale (PC1), sélectionnée selon le critère de Kaiser (valeur propre > 1) [30]. PC1 capture 68,4 % de la variance des trois scores de piliers, justifiant son usage comme agrégateur unique.




FIGURE 4.4 – Poids des piliers E, S et G extraits de PC1 au niveau 2

L'environnement domine, suivi du social, puis de la gouvernance. Cette hiérarchie est issue des corrélations observées dans les données.

4.3.4 Normalisation par rangs : une distribution uniforme

Le score brut issu de l'ACP suit une loi normale où la majorité des entreprises se concentrent autour de la moyenne. Pour accroître le pouvoir discriminant, nous appliquons une normalisation par rangs via l'outil `QuantileTransformer`. Cette technique redistribue les scores de façon homogène sur l'intervalle $[0, 100]$.




FIGURE 4.5 – Distribution du score ESG avant (loi normale) et après normalisation par rangs (loi uniforme).

Comme l'illustre la Figure 4.5, nous passons à une distribution uniforme avec une moyenne de 50,44 et des quartiles équilibrés (25^e : 25,4 ; 75^e : 75,7).

4.3.5 Neutralisation géographique : comparer des pairs locaux

Pour éviter qu'une entreprise ne soit pénalisée par sa localisation, nous centrons-réduisons le score par pays, puis appliquons un nouveau `QuantileTransformer` global.




FIGURE 4.6 – Distribution du score ESG par pays avant neutralisation




FIGURE 4.7 – Distribution du score ESG par pays après neutralisation

Le premier graphique montre que les scores varient naturellement selon le pays, créant un biais géographique. Le second graphique prouve que la méthode de centrage-réduction, préconisée par [64], élimine ce biais en alignant tous les pays sur une base commune de 50.

4.4 Robustesse Statistique du Score pour le Machine Learning

Cette étape finale valide la viabilité du score ESG comme variable cible pour les modèles prédictifs.

4.4.1 Analyse des corrélations

La Figure 4.8 présente les corrélations entre chaque pilier et le score global après neutralisation géographique.

- **Environnement** ($r = 0,723$) : Le pilier E domine. Les indicateurs d'émissions sont les plus quantifiables et les mieux harmonisés entre pays, ce qui explique leur forte contribution [5].
- **Social** ($r = 0,233$) : Le pilier S contribue le moins. Deux raisons l'expliquent : les données sociales sont peu standardisées entre pays, et la neutralisation géographique a supprimé une part importante de leur variance, qui reflétait les cadres réglementaires nationaux plutôt que les efforts individuels des entreprises [6].
- **Gouvernance** ($r = 0,521$) : Le poids de la Gouvernance passe de 0,235 avant neutralisation (Figure 4.4) à 0,521 après (Figure 4.8). Cette hausse indique que les pratiques de gouvernance sont peu liées aux contextes nationaux et constituent un facteur de performance intrinsèque [36].




FIGURE 4.8 – Corrélations piliers–score ESG global après neutralisation géographique.

4.4.2 Validation de la distribution

L'analyse confirme que la distribution suit une loi uniforme. Skewness : $-0,0134$ (parfaitement symétrique) ; Kurtosis : $-1,2108$ (aplatissement caractéristique d'une loi uniforme).

4.4.3 Pouvoir discriminant : Courbe de Lorenz

La Figure 4.9 présente la courbe de Lorenz du score final. L'indice de Gini obtenu est $G = 0,332$, quasiment identique à la valeur théorique d'une distribution uniforme ($1/3 \approx 0,333$) [19], ce qui confirme que le score utilise uniformément toute l'étendue de $[0, 100]$ sans zone sur- ou sous-représentée. Le passage d'une distribution initiale concentrée autour de la moyenne à cet

indicateur hautement discriminant constitue une condition optimale pour l'entraînement des modèles prédictifs.




FIGURE 4.9 – Courbe de Lorenz du score ESG final : distribution uniforme sur $[0, 100]$

Conclusion du chapitre

L'ACP hiérarchique et la neutralisation géographique permettent d'obtenir un score ESG continu $[0, 100]$ à distribution uniforme, garantissant l'indépendance des piliers et une pondération dictée par les données, sans intervention humaine. Ce score servira de cible au chapitre 5, avec un protocole strict visant à prévenir toute fuite de données lors de l'entraînement et du test du modèle.

Chapitre 5

Modélisation prédictive de la performance ESG

Introduction

Ce chapitre vise à prédire le score ESG construit au chapitre 4. Nous cherchons à estimer le score ESG pour de nouvelles entreprises à partir de leurs caractéristiques. Pour garantir la robustesse et éviter toute illusion de performance, nous utilisons l'année 2020, période de crise sanitaire mondiale, comme échantillon de test hors-apprentissage.

5.1 Préparation des données et stratégie d'échantillonnage

Avant de définir les modèles, cette section précise les choix effectués sur les données.

5.1.1 Rupture structurelle : le cas de l'exercice 2020

Comme l'illustre la Figure 5.1, la notation moyenne chute de 52,23 en 2019 à 47,05 en 2020. Ce recul reflète l'impact systémique de la crise sanitaire sur les indicateurs de performance, et non un désengagement des entreprises.




FIGURE 5.1 – Évolution moyenne des scores ESG par année (2018–2020)

La pandémie de COVID-19 a servi de stress-test pour les critères ESG [16]. Suivant [37], nous adoptons un split temporel strict (Tableau 5.1) :

TABLE 5.1 – Structure de l’échantillon par période

Phase	Période	Observations	Contexte
Entraînement	2018–2019	27 036	Stabilité relative
Test	2020	13 518	Rupture structurelle

Un modèle maintenant sa précision en 2020 sans avoir été exposé à ces données prouve qu’il capte la performance réelle des entreprises et que notre score repose sur des bases solides.

5.1.2 Intégrité prédictive et prévention de la circularité

Un défi majeur réside dans la prévention de la fuite de données. L’analyse des corrélations montre que certaines variables, comme `log_scope_1`, sont fortement liées à la cible ($r = 0,68$). Ces variables ayant servi à la construction du score par ACP, leur utilisation sur un échantillon aléatoire conduirait à une tautologie mathématique : le modèle se contenterait de « reconstruire » la formule au lieu d’apprendre à prédire une tendance [32].

Pour garantir l’intégrité de la prédiction, nous appliquons deux mesures :

1. **Séparation temporelle** : Le modèle ne peut pas utiliser d’informations futures pour prédire le passé.
2. **Exclusion des scores pivots** : Les scores intermédiaires (`score_E`, `score_S`, `score_G`) sont exclus des prédicteurs. L’algorithme doit se fonder uniquement sur les variables brutes transformées pour estimer la performance.

5.1.3 Codage de la variable sectorielle

Le secteur d'activité constitue un déterminant majeur de la performance extra-financière [2]. Un test ANOVA confirme cette influence sur la variance du score ESG, avec une statistique $F = 37,38$ ($p < 0,05$), justifiant l'inclusion de cette variable dans nos modèles prédictifs.




FIGURE 5.2 – Volume d'observations pour les 10 secteurs prédominants (sur 154)

Toutefois, la présence de 154 secteurs distincts (Figure 5.2) interdit l'usage du *One-Hot Encoding*, qui provoquerait une explosion de la dimensionnalité et une dilution de l'information [4]. Nous appliquons donc un *Target Encoding* : chaque modalité est remplacée par la moyenne de la variable cible calculée sur l'échantillon d'entraînement.

5.2 Modèles d'apprentissage automatique

La sélection des algorithmes vise à couvrir plusieurs familles de modèles afin d'identifier la structure de prédiction la plus adaptée aux spécificités des données ESG.

5.2.1 Régression linéaire et ElasticNet

La régression linéaire est utilisée comme point de référence pour postuler une relation linéaire entre les variables explicatives et le score ESG. Face à la forte corrélation entre certains indicateurs, nous privilégions le modèle ElasticNet [63]. Ce dernier combine deux pénalités : la norme $L1$ (Lasso), permettant une sélection automatique des variables en annulant les coefficients redondants, et la norme $L2$ (Ridge), qui stabilise les coefficients des variables dominantes.

5.2.2 Arbre de décision

L'arbre de décision est testé comme modèle non linéaire unitaire avant l'application des méthodes d'ensemble [8]. Il segmente les observations en groupes homogènes selon des seuils

critiques appliqués aux variables. Bien que très interprétable, ce modèle présente un risque de sur-apprentissage important, car il tend à mémoriser les spécificités de l'échantillon d'entraînement au détriment de la généralisation.

5.2.3 Support Vector Regression (SVR)

Le modèle SVR définit un tube d'insensibilité, noté ϵ , autour de la fonction de prédiction [59]. Par l'usage du *kernel trick*, il permet de modéliser des relations non linéaires complexes entre les indicateurs ESG et le score cible en projetant les données dans un espace de plus haute dimension. Cette méthode est reconnue pour sa robustesse face aux valeurs aberrantes présentes dans le jeu de données.

5.2.4 Random Forest

Random Forest fondé sur le principe du *bagging* [7]. L'algorithme entraîne une multitude d'arbres de décision indépendants sur des sous-échantillons aléatoires. La moyenne des prédictions des arbres réduit la variance globale du modèle et limite le risque de sur-apprentissage rencontré par un arbre isolé.

5.2.5 Gradient Boosting : XGBoost, LightGBM, CatBoost

Contrairement au *bagging*, le *boosting* est un processus séquentiel où chaque nouvel arbre est construit pour corriger les résidus laissés par le précédent. Nous comparons trois variantes :

- **XGBoost** : introduit une régularisation par pénalités L_1 et L_2 directement dans la fonction de perte pour renforcer la robustesse du modèle [12].
- **LightGBM** : utilise une croissance par feuilles (*leaf-wise*), stratégie optimisée pour converger plus rapidement sur un volume important comme nos 40 554 entrées [33].
- **CatBoost** : traite nativement les variables catégorielles, permettant d'intégrer les 154 secteurs d'activité sans encodage manuel [50].

5.2.6 Comparaison des modèles

TABLE 5.2 – Comparatif des modèles de Machine Learning.

Modèle	Famille	Non-linéarité	Points forts
Régression linéaire	Linéaire	Non	Interprétable
ElasticNet	Linéaire	Non	Sélection de variables ($L_1 + L_2$)
Arbre de décision	Arbre	Oui	Très interprétable
SVR	Noyau	Oui	Robuste aux outliers
Random Forest	Ensemble bagging	Oui	Réduit la variance
XGBoost	Ensemble boosting	Oui	Régularisation L_1/L_2
LightGBM	Ensemble boosting	Oui	Convergence rapide
CatBoost	Ensemble boosting	Oui	Traite nativement les catégories

5.3 Évaluation et optimisation des modèles

Pour mesurer la performance des modèles, nous comparons les scores ESG prédits ($\hat{y}_i$) aux valeurs réelles (y_i) issues de l'ACP. Quatre métriques complémentaires sont retenues : R^2 , RMSE, MAE et MedAE.

5.3.1 Métriques d'évaluation

Dans toutes les formules suivantes, n désigne le nombre d'observations dans l'échantillon test ($n = 13\,518$), $\hat{y}_i$ la prédiction pour l'observation i , y_i la valeur réelle, et $\bar{y}$ la moyenne des y_i .

Erreur quadratique moyenne (RMSE)

La *Root Mean Square Error* (RMSE) mesure l'écart type des résidus. Cette métrique accorde un poids plus important aux erreurs de grande ampleur du fait de l'élévation au carré des écarts [11]. Elle est définie par :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (5.1)$$

Erreur absolue moyenne (MAE)

La *Mean Absolute Error* (MAE) représente la moyenne des valeurs absolues des erreurs. Contrairement à la RMSE, elle traite toutes les erreurs avec le même poids, offrant une vision plus linéaire de la précision du modèle [61]. Sa formule est :

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5.2)$$

Erreur absolue médiane (MedAE)

Compte tenu de la présence de profils ESG atypiques, nous utilisons la *Median Absolute Error* (MedAE). Cette métrique est particulièrement robuste aux valeurs aberrantes car elle n'est pas influencée par les erreurs extrêmes situées en queue de distribution [54]. Elle se calcule comme suit :

$$\text{MedAE} = \text{médiane}(|y_1 - \hat{y}_1|, \dots, |y_n - \hat{y}_n|) \quad (5.3)$$

Coefficient de détermination (R^2)

Le coefficient R^2 mesure la proportion de la variance de la variable cible expliquée par les variables indépendantes du modèle [44]. Un score proche de 1 indique que le modèle reproduit fidèlement la variabilité du score ESG :

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (5.4)$$

5.3.2 Optimisation des hyperparamètres et validation

L’optimisation des modèles repose sur une recherche aléatoire (*Randomized Search*) de 50 itérations par modèle. Cette méthode permet d’explorer l’espace des hyperparamètres pour identifier la combinaison minimisant l’erreur quadratique moyenne (MSE). Pour garantir la robustesse des estimations sur des données de panel, la validation croisée est effectuée via un découpage chronologique (*TimeSeriesSplit*) [26].

5.4 Résultats et évaluation

5.4.1 Comparaison des performances

Le Tableau 5.3 synthétise les résultats obtenus sur l’échantillon de test (année 2020).

TABLE 5.3 – Tableau comparatif des performances des modèles sur l’année de test (2020)

Modèle	R^2 train	R^2 test	RMSE	MAE	MedAE	Temps (s)	ΔR^2
CatBoost	0,9618	0,9532	6,65	4,95	3,78	186,6	0,0086
LightGBM	0,9623	0,9497	6,90	5,09	3,84	164,5	0,0127
XGBoost	0,9650	0,9496	6,90	5,10	3,86	129,7	0,0154
RandomForest	0,9831	0,9407	7,49	5,39	3,94	2 541,5	0,0424
SVR	0,9420	0,9385	7,63	5,54	4,03	4 277,4	0,0035
DecisionTree	0,9521	0,9053	9,46	6,70	4,75	23,0	0,0467
LinearReg	0,8103	0,8194	13,07	9,73	7,60	0,05	−0,0091
ElasticNet	0,8087	0,8189	13,09	9,75	7,61	237,9	−0,0103

5.4.2 Analyse des résultats

Le tableau 5.3 permet plusieurs observations. **CatBoost** obtient le meilleur R^2 test (0,9532) et l’erreur médiane la plus faible (3,78 points). Son écart de R^2 entre l’entraînement et le test (0,0086) est très faible, signe d’absence de sur-apprentissage. Le temps d’entraînement (186 secondes) est raisonnable.

Random Forest sur-apprend nettement ($\Delta R^2 = 0,0424$) et est très lent (42 minutes). **LightGBM** et **XGBoost** sont proches de CatBoost mais légèrement moins précis. Les modèles linéaires (Régression, ElasticNet) plafonnent à $R^2 \approx 0,82$, confirmant la non-linéarité des relations ESG.

5.5 Validation et interprétation du modèle CatBoost

À l’issue de la phase comparative, le modèle *CatBoost* a été sélectionné comme moteur de prédiction principal. Cette section vise à valider la qualité de ses estimations sur l’année de test 2020 et à lever l’effet « boîte noire » par une analyse de l’importance des variables.

5.5.1 Analyse de la précision et des résidus

La Figure 5.3 compare les scores ESG réels aux prédictions du modèle sur le test. L'alignement des points autour de la diagonale confirme le R^2 de 0,9532 : le modèle positionne correctement les entreprises sur l'ensemble du continuum ESG.




FIGURE 5.3 – Comparaison des scores ESG réels et prédits (CatBoost, échantillon 2020)

La distribution des résidus (Figure 5.4) est centrée sur zéro et symétrique. Les erreurs sont aléatoires : pas de tendance à sur-évaluer ou sous-évaluer. La MedAE de 3,78 points confirme cette neutralité.




FIGURE 5.4 – Distribution des résidus du modèle CatBoost

5.5.2 Importance des variables et transparence de l'audit

Conformément aux principes de l'intelligence artificielle responsable, nous utilisons les valeurs SHAP (*SHapley Additive exPlanations*) pour interpréter les décisions du modèle. Cette approche, issue de la théorie des jeux, garantit une distribution équitable de l'importance entre les variables explicatives [38].




FIGURE 5.5 – Importance SHAP des variables (contribution moyenne)

Le classement issu des valeurs SHAP (Figure 5.5) identifie deux moteurs prédominants :

1. **log_revenue_wins** (Taille de l'entreprise) : Il s'agit du facteur le plus influent. Cela traduit une réalité de marché où le volume d'activité est souvent corrélé à la capacité d'investissement dans des structures de gouvernance et de *reporting* plus matures.
2. **log_scope_1** (Émissions directes) : Cette variable constitue le second levier de prédiction. Elle confirme que l'empreinte carbone directe reste le déterminant majeur du risque environnemental dans notre structure de score.

Conclusion du chapitre

Ce chapitre a transformé le score statique du chapitre 4 en un moteur prédictif performant. La comparaison de huit algorithmes a montré la supériorité de **CatBoost**, qui atteint un R^2 de 0,9532 sur l'année test 2020 et généralise bien. Le test sur l'année de crise COVID-19 confirme la robustesse de notre score ESG. Les valeurs SHAP identifient la taille de l'entreprise et ses émissions directes comme les deux principaux leviers de prédiction.

Cette modélisation constitue le cœur analytique du projet. Pour en faire un outil d'aide à la décision, le chapitre suivant détaille l'architecture et le déploiement de la plateforme ESG intelligente, intégrant Power BI et un assistant conversationnel RAG.

Chapitre 6

Architecture, Développement et Déploiement de la Plateforme ESG

Ce chapitre présente les éléments clés qui définissent la structure et le développement de la plateforme ESG. Nous commençons par spécifier les besoins du projet — fonctionnels et non fonctionnels — afin de garantir que la solution répond aux exigences métier réelles. Nous présentons ensuite les diagrammes essentiels permettant de visualiser le fonctionnement du système et les interactions entre ses composants. Enfin, nous parcourons les fonctionnalités principales de l'application, offrant une vue claire des outils mis à disposition des utilisateurs et des administrateurs. L'ensemble de ces éléments pose les fondations d'une plateforme ESG intelligente et modulaire, capable de prédire les scores ESG, de générer des recommandations personnalisées et de permettre une interaction en langage naturel via le chatbot *ESGénie*.

6.1 Capture des besoins

6.1.1 Identification des acteurs

Dans le contexte d'un projet informatique, un acteur désigne toute entité humaine ou technique qui interagit directement avec le système. L'identification des acteurs permet de structurer les cas d'utilisation de manière efficace, en se concentrant sur les exigences spécifiques et les tâches que chaque intervenant est supposé réaliser.

Pour la plateforme ESG, nous distinguons trois acteurs humains principaux :

- **Utilisateur métier (analyste ESG / responsable RSE) :** il constitue l'acteur principal de la plateforme. Il dispose d'un accès complet aux fonctionnalités de consultation et d'analyse ESG sur le périmètre de l'entreprise qui lui est assignée. Il peut :
 - S'authentifier et gérer son profil personnel (nom, mot de passe, avatar).
 - Consulter les données et les indicateurs ESG de son entreprise.
 - Saisir les indicateurs ESG et lancer le calcul du score via le module *ESG Studio*.
 - Consulter l'historique des scores ESG et leur évolution temporelle.
 - Interroger le chatbot *ESGénie* par saisie textuelle ou commande vocale.

- Consulter les recommandations d'amélioration personnalisées.
- Accéder aux actualités ESG agrégées.
- Consulter les tableaux de bord analytiques.
- **Décideur (direction / manager ESG) :** il exploite les résultats produits par la plateforme pour orienter les décisions stratégiques. Il ne saisit pas les données métier mais consomme les informations consolidées. Il peut :
 - Consulter les tableaux de bord ESG et les indicateurs clés de performance.
 - Suivre les tendances sectorielles et l'évolution des scores ESG.
 - Accéder aux recommandations générées pour prioriser les actions d'amélioration.
 - Consulter les synthèses et les comparaisons liées à son périmètre d'entreprise.
- **Administrateur :** il est responsable de la gestion des accès et de la supervision de la plateforme. Il hérite de tous les privilèges des autres profils et dispose en plus des droits suivants :
 - Gérer la vérification des comptes (activation par e-mail) et bloquer ou débloquer des utilisateurs.
 - Consulter et gérer l'ensemble des comptes utilisateurs.
 - Modifier les rôles des utilisateurs.
 - Assigner ou retirer une entreprise à un utilisateur.
 - Supprimer des comptes utilisateurs.
 - Créer, modifier et supprimer les entreprises.

Acteurs secondaires

Les acteurs secondaires sont des systèmes tiers externes que la plateforme sollicite afin d'exécuter certains cas d'utilisation ou de fournir des services complémentaires.

- **Fournisseur LLM (OpenAI ou Groq) :** intervient dans le cadre de l'assistant conversationnel ESGénie pour la génération des réponses en langage naturel.
- **Serveur e-mail (SMTP / Gmail) :** utilisé lors de l'inscription, de la vérification des comptes utilisateurs et de la réinitialisation des mots de passe.
- **Service d'actualités ESG (News API) :** fournit les actualités ESG affichées au sein de la plateforme.
- **Applications clientes externes :** applications tierces pouvant consommer l'API REST de la plateforme afin d'intégrer les fonctionnalités de prédiction ESG, de consultation des données ou d'analyse dans leurs propres systèmes.

TABLE 6.1 – Synthèse des acteurs de la plateforme ESG

Acteur	Rôle principal
Utilisateur métier	Consultation des données ESG de son entreprise, réalisation de prédictions, utilisation du chatbot ESGénie et consultation des recommandations.
Décideur	Consultation des indicateurs ESG, des tableaux de bord analytiques et des recommandations afin de soutenir la prise de décision stratégique.
Administrateur	Gestion des comptes utilisateurs, des rôles, des accès et des entreprises, ainsi que validation des inscriptions.
Fournisseur LLM	Génération des réponses de l'assistant conversationnel ESGénie.
Serveur e-mail	Envoi des e-mails de vérification de compte et de réinitialisation des mots de passe.
Service d'actualités ESG	Fourniture des actualités ESG affichées sur la plateforme.
Applications clientes externes	Consommation de l'API REST pour l'intégration des fonctionnalités ESG dans des systèmes tiers.

6.1.2 Besoins fonctionnels

Les besoins fonctionnels définissent l'ensemble des services que la plateforme doit fournir à ses utilisateurs. Ils sont organisés selon les principales fonctionnalités offertes par le système.

TABLE 6.2 – Besoins fonctionnels de la plateforme ESG

Fonctionnalité	Description
Authentification	La plateforme permet la création et la gestion des comptes utilisateurs. Le rôle est attribué par l'administrateur après inscription. Le système assure l'authentification sécurisée et la réinitialisation du mot de passe par e-mail. L'activation du compte repose sur deux étapes : (1) validation par l'administrateur, (2) vérification de l'adresse électronique.
Gestion des rôles	La plateforme contrôle l'accès aux fonctionnalités selon le profil de l'utilisateur : <i>métier</i> , <i>décideur</i> ou <i>administrateur</i> .
Profil utilisateur	Chaque utilisateur peut consulter et mettre à jour ses informations personnelles (nom, mot de passe, avatar). Toute modification est enregistrée immédiatement.
Gestion des entreprises	L'administrateur crée, modifie et supprime les entreprises. L'utilisateur métier consulte les informations de l'entreprise qui lui est attribuée. Un historique des évaluations ESG est conservé pour le suivi de leur évolution.
Prédiction ESG	La plateforme calcule automatiquement un score ESG à partir des données saisies. Chaque prédiction est enregistrée dans un historique, accompagnée d'une interprétation qualitative et exportable en rapport.
Tableau de bord analytique	Un tableau de bord visualise les principaux indicateurs ESG et leur évolution dans le temps, permettant de suivre la performance et d'identifier les tendances significatives.
Analyse et visualisations	Des fonctionnalités d'analyse permettent d'explorer les scores ESG, leurs distributions, leurs tendances et les comparaisons entre entreprises ou secteurs d'activité.
Recommandations ESG	La plateforme génère des recommandations personnalisées couvrant les dimensions Environnement, Social et Gouvernance, adaptées à la situation de chaque entreprise.
Chatbot ESGénie	Un assistant conversationnel permet d'interroger la base de connaissances ESG en langage naturel, avec une interaction textuelle ou vocale et des réponses contextualisées.
Actualités ESG	La plateforme récupère automatiquement des actualités ESG récentes, consultables par catégorie et centre d'intérêt.

6.1.3 Besoins non fonctionnels

Les besoins non fonctionnels décrivent les exigences liées à la qualité, à la performance et à la robustesse du système.

TABLE 6.3 – Besoins non fonctionnels de la plateforme ESG

Exigence	Description
Sécurité	La plateforme garantit un niveau élevé de sécurité à travers l’authentification JWT stockée dans des cookies <code>HttpOnly</code> , la validation des entrées via schémas Pydantic, le rate limiting par adresse IP sur les endpoints sensibles, la restriction CORS aux origines autorisées, le hachage des mots de passe avant persistance et la gestion des secrets via variables d’environnement.
Performance	Les temps de réponse pour les modules d’inférence ML et du chatbot doivent être adaptés à une utilisation interactive en quasi temps réel (<i>near real-time</i>). Le modèle CatBoost est chargé en mémoire lors du premier appel d’inférence (patron singleton).
Résilience	Le système assure la continuité du service et la persistance des données, modèles et index, même en cas de redémarrage ou de défaillance partielle. Le mécanisme de <i>fallback</i> en cascade du LLM (Groq → OpenAI) améliore la disponibilité du chatbot en cas d’indisponibilité d’un fournisseur de modèle.
Traçabilité	Les actions métier critiques font l’objet d’une journalisation. Les événements d’authentification (tentatives, succès, échecs) et les erreurs système sont tracés via le module <code>logging</code> Python. Les prédictions ESG sont persistées dans la table <code>prediction_history</code> avec l’identifiant utilisateur, les métriques saisies, le score et l’horodatage. L’historique des conversations du chatbot <i>ESGénie</i> est conservé par compte utilisateur dans les tables <code>ChatConversation</code> et <code>ChatMessage</code> .
Maintenabilité	L’architecture modulaire multi-services et la conteneurisation via Docker permettent la mise à jour indépendante de chaque composant (frontend, backend, service RAG, base de données) sans impact sur l’ensemble du système.
Déploiement reproductible	La solution est déployable de manière homogène sur différents environnements grâce à Docker et Docker Compose. Les modèles ML sont téléchargés via un script dédié (<code>download_models.py</code>), garantissant la portabilité entre développement et production.

6.1.4 Diagramme de cas d'utilisation

Ce diagramme illustre les interactions entre les trois acteurs humains de la plateforme et ses fonctionnalités principales.

Note : toute interaction avec la plateforme nécessite une authentification préalable, non représentée dans le diagramme afin de ne pas surcharger sa lisibilité.

L'**Utilisateur métier** accède aux fonctionnalités opérationnelles : gestion du profil, calcul du score ESG, consultation de l'historique des scores, de son entreprise assignée, des actualités ESG et interrogation du chatbot *ESGénie* — par saisie textuelle ou par commande vocale («étend»).

Le **Décideur**, qui hérite des privilèges de l'utilisateur métier, dispose en complément de l'accès au tableau de bord, aux indicateurs analytiques et aux recommandations ESG.

L'**Administrateur**, qui hérite de l'ensemble des privilèges des deux profils précédents, dispose en plus de la gestion des entreprises et de la gestion des utilisateurs, laquelle s'étend à quatre actions : modification du rôle, assignation d'une entreprise, blocage d'un compte et suppression d'un compte.

Les systèmes externes sont sollicités via des relations «*inclut*» : le **Service IA** (Groq/OpenAI et Moteur RAG) intervient lors du calcul du score ESG, de l'interrogation du chatbot, de la consultation des indicateurs analytiques et des recommandations. Le **Service Actualités** alimente la consultation des actualités, et le **Service Voix** prend en charge l'interrogation par commande vocale.




FIGURE 6.1 – Diagramme de cas d'utilisation de la plateforme ESG

6.1.5 Diagramme de classes

Ce diagramme présente la structure statique de la plateforme ESG à travers ses principales classes et leurs relations.

La classe centrale **User** regroupe les informations d’authentification, de rôle et d’état du compte (`is_approved`, `is_verified`, `is_blocked`). Elle est associée à six entités : **PasswordResetToken** et **EmailVerificationToken** pour la gestion sécurisée des tokens d’authentification, **Company** via deux relations distinctes — *crée* pour la traçabilité de la création et *appartient à* pour le rattachement opérationnel d’un utilisateur métier à son entreprise —, **PredictionHistory** pour l’historique des scores ESG calculés, et **ChatConversation** pour les sessions de dialogue avec le chatbot *ESGénie*. Chaque conversation est composée d’un ensemble de **ChatMessage**.

Deux services complètent le diagramme : le **MLService** encapsule le modèle CatBoost et est sollicité via une dépendance «*use*» par *PredictionHistory* pour le calcul des scores, et l’**IntegrationService** est utilisé par *ChatConversation* pour le traitement des réponses du chatbot RAG.




FIGURE 6.2 – Diagramme de classes

6.1.6 Diagrammes de séquence

Les diagrammes de séquence suivants illustrent les flux d’interaction entre les composants de la plateforme pour trois scénarios clés : l’authentification, la prédiction ESG et le chatbot

ESGénie. Ces diagrammes adoptent une approche orientée objet en nommant explicitement les participants sous la forme **instance** : **Classe** et en exposant les appels de méthodes réels issus du code source.

Authentification

Ce diagramme décrit le flux de connexion d'un utilisateur à la plateforme. Après soumission du formulaire, le backend effectue deux vérifications préalables : le respect du rate limiting (5 req/min) et la validité du format des données. Si ces contrôles sont franchis, les identifiants sont vérifiés en base de données et le mot de passe est comparé via `bcrypt`.

Quatre scénarios d'échec sont distingués selon l'état du compte : identifiants invalides (401), compte bloqué, non approuvé ou e-mail non vérifié (403). En cas de succès, un cookie JWT (`HttpOnly`, `SameSite=Lax`) est émis et l'utilisateur est redirigé vers le tableau de bord.




FIGURE 6.3 – Diagramme de séquence — Authentification

Prédiction ESG

Ce diagramme décrit le calcul d'un score ESG depuis la saisie des indicateurs jusqu'à l'affichage du résultat. Après contrôle du rôle et validation des données d'entrée, la requête est déléguée au `MLService` qui charge le modèle `CatBoost` de manière lazy (patron singleton) et retourne le score calculé.

La persistance de la prédiction dans l'historique est effectuée en mode *best effort* : un échec de sauvegarde n'empêche pas le retour du score à l'utilisateur.




FIGURE 6.4 – Diagramme de séquence — Prédiction ESG

Chatbot RAG (ESGénie)

Ce diagramme illustre le traitement d’une question posée au chatbot *ESGénie*. La requête est d’abord classifiée selon son intention : une question conversationnelle (SMALLTALK) reçoit une réponse directe, tandis qu’une question ESG (RAG ou GENERAL) déclenche une recherche sémantique dans l’index FAISS suivie d’une génération de réponse par LLM.

La sélection du fournisseur LLM suit une stratégie de fallback en cascade : Groq est sollicité en priorité, OpenAI prend le relais en cas d’indisponibilité, et un mécanisme de secours local retourne les extraits documentaires bruts si les deux services sont inaccessibles.




FIGURE 6.5 – Diagramme de séquence — Chatbot RAG (ESGénie)

6.1.7 Choix technologiques & Architecture

La plateforme ESG repose sur un ensemble de technologies modernes combinant développement web, intelligence artificielle, traitement sémantique et conteneurisation. Les principales technologies utilisées ainsi que leur rôle dans l’architecture globale sont présentés dans le tableau suivant.

TABLE 6.4 – Environnement technologique de la plateforme ESG

Technologie	Rôle dans la plateforme
React + TypeScript + Vite	Développement du frontend SPA interactif et responsive
Flask (Python)	API REST, logique métier et orchestration des services
PostgreSQL	Persistance des données relationnelles
CatBoost	Prédiction et calcul des scores ESG
FAISS	Recherche vectorielle et indexation sémantique
SentenceTransformers	Génération des embeddings locaux pour le système RAG
Groq / OpenAI API	Modèles de langage (LLM) pour la génération de réponses et le chatbot <i>ESGénie</i>
Docker & Docker Compose	Conteneurisation et orchestration multi-services
Serveur SMTP externe	Envoi des courriers électroniques (vérification de compte, notifications)
Power BI & Recharts	Visualisation analytique, graphiques intégrés et tableaux de bord ESG

6.2 Architecture & Déploiement

Architecture générale de la plateforme

La plateforme ESG repose sur une architecture modulaire multi-services organisée en trois couches principales.

La **couche de présentation** est développée avec React, TypeScript et Vite. Elle assure l’affichage des tableaux de bord, des analyses ESG, des formulaires de prédiction et de l’interface du chatbot.

La **couche métier** est assurée par le backend Flask, qui centralise l’authentification, la gestion des utilisateurs et des entreprises, l’orchestration des prédictions ESG et l’administration de la plateforme. Il expose les API REST consommées par le frontend et délègue les traitements spécialisés aux services dédiés.

La **couche de services spécialisés** comprend le service RAG, maintenu indépendant pour des raisons de performance, qui gère la recherche sémantique via FAISS et la génération de réponses via les LLM externes (Groq, OpenAI). PostgreSQL assure la persistance des données, et un serveur SMTP externe (Gmail) gère les courriels transactionnels.

Le fonctionnement global suit une logique orientée services : le frontend communique avec le backend via des requêtes REST sécurisées par JWT, tandis que le backend délègue les inférences ML et les recherches RAG aux services concernés.




FIGURE 6.6 – Architecture générale de la plateforme ESG

Déploiement avec Docker

La plateforme est déployée via **Docker Compose** [41], orchestrant quatre services — frontend, backend Flask, service RAG et PostgreSQL — sur un réseau commun (**esg-network**) permettant la communication inter-conteneurs par nom de service.

Le frontend React/Vite est compilé en image multi-étapes puis servi par Nginx, avec un proxy inverse vers le backend Flask. Les services backend et RAG utilisent des images Python légères, tandis que PostgreSQL bénéficie d'un volume nommé (**postgres_data**) garantissant la durabilité des données entre redéploiements. L'index vectoriel FAISS et les ressources du modèle sont conservés via un bind mount, évitant toute reconstruction d'image à chaque redémarrage.

L'ensemble des services se lance en une seule commande :

```
docker compose up --build
```

Cette approche garantit un déploiement homogène, portable et reproductible, aussi bien en développement qu'en production.

6.2.1 Authentification & gestion des rôles

La plateforme ESG intègre un système d'authentification sécurisé garantissant que seuls les utilisateurs autorisés peuvent accéder aux fonctionnalités de la plateforme. La gestion des accès

repose sur une architecture à **trois rôles** distincts : l'**Administrateur** (admin), qui dispose de l'ensemble des privilèges du système ; le **Décideur** (decideur), orienté vers l'analyse et les tableaux de bord stratégiques ; et l'**Utilisateur Métier** (metier), dont les accès sont limités aux fonctionnalités opérationnelles qui lui sont attribuées.

Connexion

La page de connexion constitue le point d'entrée principal de la plateforme. En cas de succès, un cookie JWT (`HttpOnly`, `SameSite=Lax`) est généré et l'utilisateur est redirigé vers le tableau de bord. En cas d'identifiants incorrects, un message générique est affiché sans révéler d'informations sensibles sur le compte.

Bienvenue
Connectez-vous pour accéder à la plateforme.

Email
dissem.tasnim@gmail.com

Mot de passe
.....

[Se connecter →](#)

[Créer un compte](#) [Mot de passe oublié ?](#)

FIGURE 6.7 – Page de connexion

Bienvenue
Connectez-vous pour accéder à la plateforme.

Connexion échouée. Vérifiez votre e-mail et votre mot de passe.

Email
dissem.tasnim@gmail.com

Mot de passe
.....

[Se connecter →](#)

[Créer un compte](#) [Mot de passe oublié ?](#)

FIGURE 6.8 – Identifiants incorrects

Inscription

Les utilisateurs soumettent une demande d'inscription en renseignant leur nom, adresse e-mail et mot de passe.

FIGURE 6.9 – Page d’inscription

Une fois le formulaire soumis, le compte est créé avec les indicateurs `is_approved = false` et `is_verified = false` et reste inactif jusqu’à validation en deux phases : approbation par l’administrateur, puis confirmation de l’adresse e-mail via un lien sécurisé à usage unique valable 24 heures.




FIGURE 6.10 – E-mail d’activation reçu après approbation

Réinitialisation du mot de passe

En cas d’oubli du mot de passe, la plateforme propose une fonctionnalité de réinitialisation accessible directement depuis la page de connexion. L’utilisateur saisit son adresse e-mail ; un lien de réinitialisation lui est alors envoyé automatiquement par courrier électronique. En cliquant sur ce lien, il est redirigé vers une page sécurisée où il peut définir un nouveau mot de passe. Ce mécanisme garantit une récupération d’accès sécurisée grâce à l’utilisation d’un jeton de réinitialisation à usage unique haché en **SHA-256**, dont la durée de validité est limitée à

15 minutes. Le taux de demandes est limité à 3 par heure par adresse IP afin de prévenir les abus.




FIGURE 6.11 – Page de réinitialisation du mot de passe

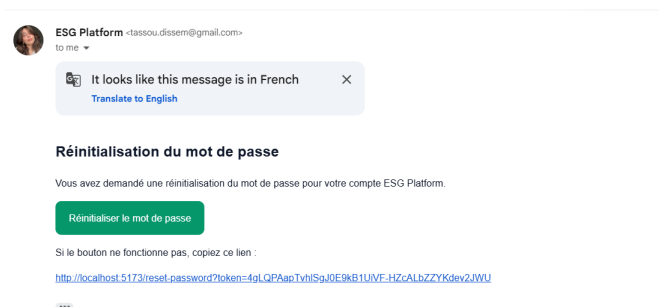


FIGURE 6.12 – E-mail de réinitialisation reçu par l'utilisateur




FIGURE 6.13 – Page de saisie du nouveau mot de passe

6.2.2 Administration de la plateforme

Le panneau d'administration est exclusivement accessible aux utilisateurs disposant du rôle **admin**. Il centralise la gestion des comptes utilisateurs et le contrôle des accès à la plateforme.

Gestion des utilisateurs

L'interface d'administration liste l'ensemble des comptes enregistrés avec leurs informations principales : nom, adresse e-mail, rôle attribué et statut du compte. L'administrateur peut approuver les demandes d'inscription en attente — ce qui déclenche l'envoi de l'e-mail d'activation —, modifier le rôle d'un utilisateur parmi les valeurs disponibles (`metier`, `decideur`, `admin`), suspendre un compte (`is_blocked`) et supprimer des comptes. Ces actions sont sécurisées côté serveur par le décorateur `admin_required`, qui vérifie le JWT et le rôle avant d'autoriser chaque opération.

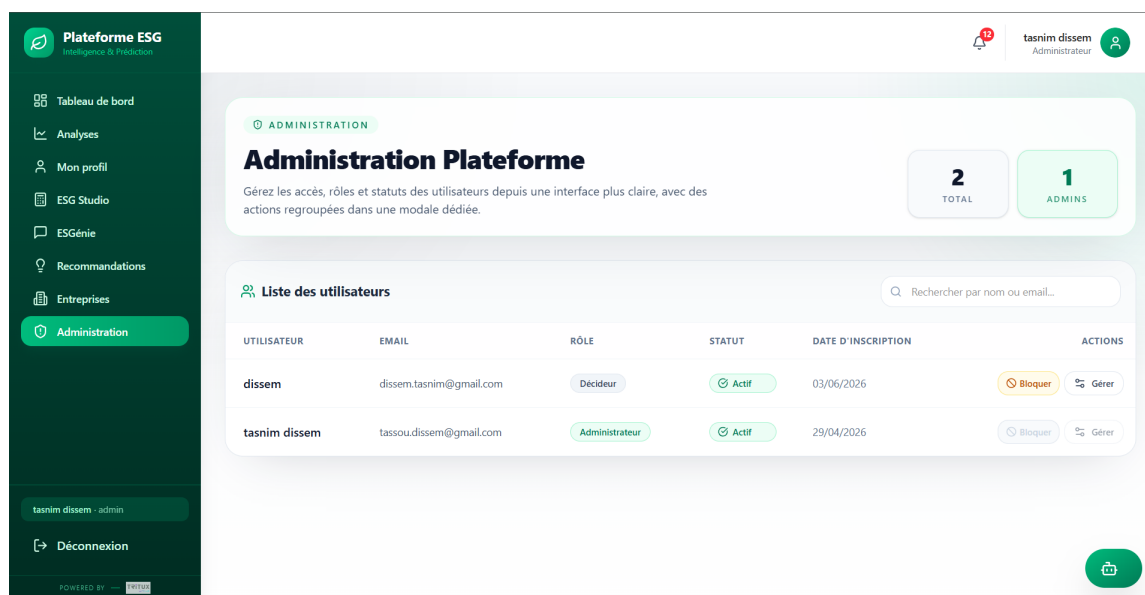


FIGURE 6.14 – Panneau d'administration — gestion des utilisateurs et des rôles

6.2.3 Gestion des entreprises

Le module de gestion des entreprises permet de créer, consulter, modifier et supprimer les entités métier enregistrées dans la plateforme. Les opérations d'écriture sont réservées aux administrateurs ; les utilisateurs métier disposent d'un accès en lecture seule à l'entreprise qui leur est assignée. Chaque entrée affiche le dernier score ESG calculé, le secteur, le pays et la date de mise à jour. Une barre de recherche permet de filtrer rapidement les entrées, et un bouton "*Calculer score*" permet de relancer une prédiction directement depuis la liste.




FIGURE 6.15 – Interface de gestion des entreprises — liste et actions CRUD

La création s'effectue via une fenêtre modale demandant le nom de l'entreprise (obligatoire), le secteur et le pays (optionnels). La suppression est sécurisée par une confirmation avertissant de la perte irréversible des historiques associés.

FIGURE 6.16 – Création d'une entreprise

FIGURE 6.17 – Confirmation de suppression

La page de détail présente l'évolution temporelle du score ESG global sous forme de graphe ainsi que l'historique complet des prédictions avec les sous-scores environnemental (E), social (S) et de gouvernance (G).




FIGURE 6.18 – Historique des scores ESG et évolution temporelle

6.2.4 Module de prédiction ESG

Le module *ESG Studio* met à disposition un calculateur de score ESG structuré en trois catégories de métriques : informations générales de l'entreprise (secteur, capitalisation, effectifs), indicateurs environnementaux (émissions Scope 1/2/3, énergie, déchets, eau) et indicateurs sociaux et de gouvernance (formation, composition du conseil, rémunération). L'utilisateur renseigne les valeurs puis soumet le formulaire pour déclencher l'inférence.


Calculateur de Score ESG

Entrez les métriques de l'entreprise pour calculer son score ESG via notre modèle.

Informations Entreprise

Secteur d'activité

Technologie

Valeur boursière de l'entreprise

0

Nombre total d'employés

9.525

Chiffre d'affaires annuel

21.679

Environnement (E)

Les valeurs numériques sont en **échelle logarithmique**. Ex : 1 000 employés → entrez -6.9 (ln(1000)). Utilisez un calculateur si besoin.

Émissions CO₂ directes (usines, véhicules)

0

Émissions CO₂ de l'électricité achetée

0

Émissions CO₂ chaîne d'approvisionnement

0

Consommation d'énergie totale (MWh)

11.87

Déchets produits (tonnes)

12.119

Eau consommée (m³)

13.53

Ratio CO₂ direct / chiffre d'affaires

0

Ratio énergie / chiffre d'affaires

10.44

Ratio déchets / chiffre d'affaires

13.38

Social & Gouvernance (S & G)

Heures de formation des employés

7.739

% d'administrateurs indépendants

25

Rémunération annuelle du PDG (€)

0

Montant des litiges et amendes payés

0

Chiffre d'affaires généré par employé

0

Revenus en baisse cette année ? (0 = Non, 1 = Oui)

0

⚡ Prédire le Score ESG

FIGURE 6.19 – Formulaire de saisie des métriques ESG — ESG Studio

Le score global est restitué instantanément avec une interprétation qualitative du niveau de performance. L'utilisateur peut exporter le résultat en PDF ou l'enregistrer dans le dossier d'une entreprise suivie.

69




FIGURE 6.20 – Résultat de la prédiction — Score ESG global et interprétation

6.2.5 Analyse ESG et visualisations

Le module d'analytics présente des visualisations interactives permettant d'explorer les distributions de scores, les tendances sectorielles et les corrélations entre les dimensions ESG, avec des comparaisons multi-entreprises et multi-périodes.




FIGURE 6.21 – Module d’analytics ESG — visualisations et comparaisons

6.2.6 Gestion du profil utilisateur

Chaque utilisateur peut consulter et modifier ses informations personnelles : nom d’affichage, mot de passe (avec vérification de l’ancien) et avatar via téléversement d’image stockée sur Amazon S3.

The screenshot shows the 'Mon profil' page of the 'Plateforme ESG' interface. The left sidebar is identical to the previous figure. The main content area is titled 'Mon profil' and includes the instruction 'Modifiez vos informations personnelles et votre mot de passe.' The page is divided into two main sections:

- Photo de profil:** Displays a circular profile picture with the initials 'TD'. Below it, the text reads 'Photo de profil' and 'PNG, JPG ou WEBP jusqu'à 5 Mo.' There is a button 'Choisir une image'.
- Informations du compte:** Contains fields for 'Nom' (tasnim dissem) and 'Email' (tassou.dissem@gmail.com). Below this is a 'Sécurité' section with a note 'Changez votre mot de passe sans passer par le formulaire de réinitialisation.' It includes fields for 'Mot de passe actuel' (masked with dots), 'Nouveau mot de passe' (masked with dots), and 'Confirmation' (masked with dots). A button 'Enregistrer les modifications' is at the bottom right.

The interface also includes a top navigation bar with the user's name 'tasnim dissem' and role 'Administrateur', and a bottom bar with a 'Déconnexion' button.

FIGURE 6.22 – Page de gestion du profil utilisateur

6.2.7 Système de recommandation ESG

Le module de recommandation génère automatiquement des actions personnalisées visant à améliorer la performance ESG de l’entreprise. Les recommandations couvrent les trois dimensions (Environnement, Social, Gouvernance) et sont présentées sous forme de cartes précisant l’impact

attendu, l'effort requis et le délai indicatif. Des filtres par catégorie et par priorité permettent de cibler rapidement les actions les plus pertinentes.




FIGURE 6.23 – Système de recommandation ESG — cartes d'action personnalisées

6.2.8 Assistant conversationnel (Chatbot RAG) — *ESGénie*

L'assistant conversationnel *ESGénie* permet aux utilisateurs d'interroger en langage naturel une base de connaissances ESG constituée de documents PDF (rapports ESG, normes, référentiels) et des données du jeu de données d'entraînement, indexés via le pipeline RAG. Il fournit des réponses contextualisées accompagnées des références documentaires mobilisées, garantissant la traçabilité des informations présentées. L'historique des échanges est conservé en base de données, assurant la continuité contextuelle entre les sessions.

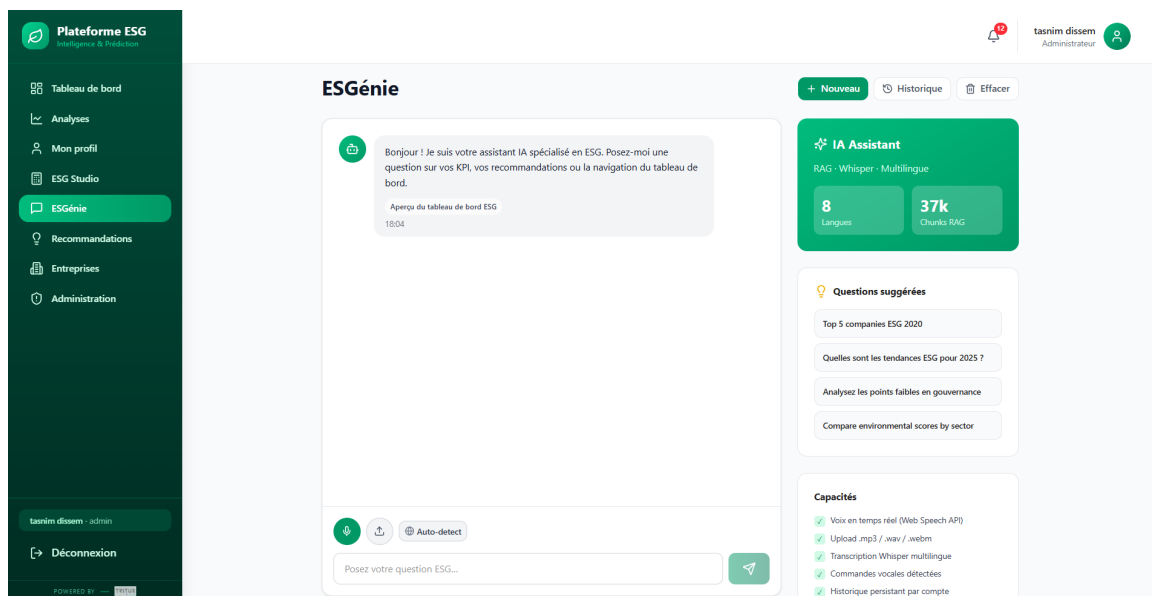


FIGURE 6.24 – Interface du chatbot *ESGénie* — réponse RAG avec sources documentaires

Interaction vocale

En complément de la saisie textuelle, *ESGénie* intègre une fonctionnalité d'interrogation par commande vocale. La question est transcrite automatiquement en texte, puis traitée par le pipeline RAG de manière identique à une requête saisie au clavier.

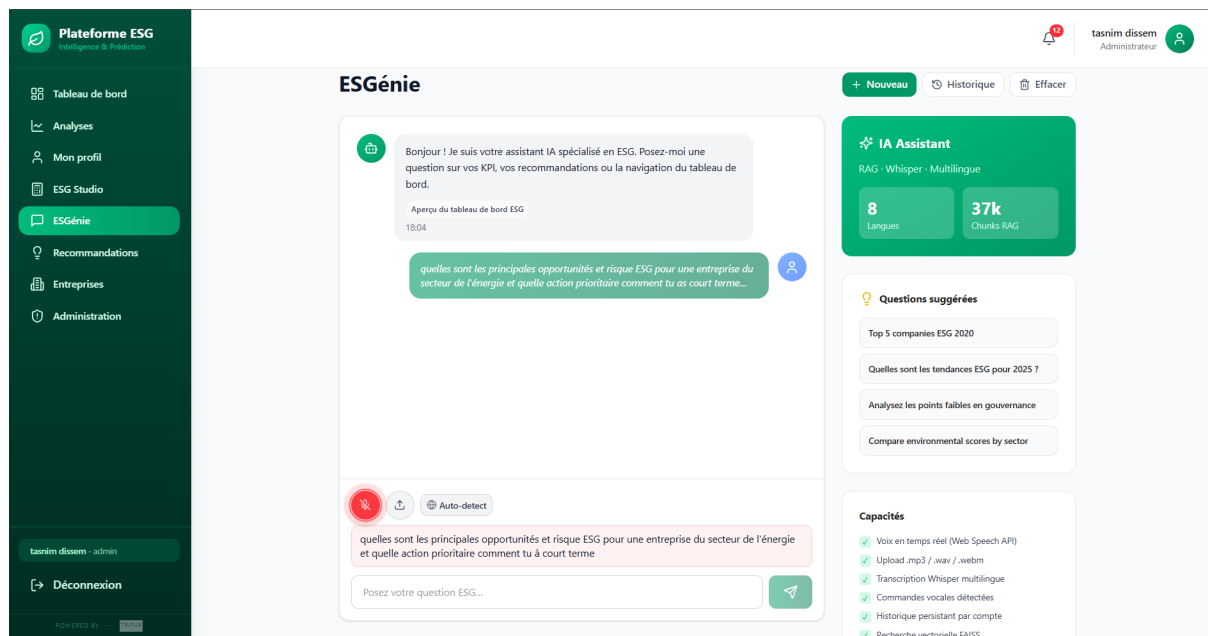


FIGURE 6.25 – Interrogation vocale du chatbot *ESGénie*

6.2.9 Agrégation d'actualités ESG

La plateforme intègre un module d'agrégation d'actualités ESG permettant de récupérer automatiquement des articles récents depuis des sources externes spécialisées. Les contenus collectés sont classifiés automatiquement selon les trois dimensions ESG — Environnement, Social et Gouvernance — à partir d'une analyse par mots-clés du titre et de la description de chaque article.

L'interface propose un panneau déroulant accessible depuis l'en-tête de la plateforme, affichant pour chaque article sa catégorie, son titre, un extrait de description, sa source et sa date de publication. Des onglets de filtrage permettent de restreindre l'affichage par dimension ESG, et un bouton de rafraîchissement permet de relancer la collecte à la demande.




FIGURE 6.26 – Module d’agrégation des actualités ESG

6.2.10 Implémentation du modèle de Machine Learning

Le modèle CatBoost [50], stocké au format natif `.cbm`, est intégré au backend Flask via un service dédié (`MLService`). Il est chargé en mémoire lors du premier appel d’inférence via un patron singleton, évitant tout rechargement ultérieur. L’endpoint `POST /api/predict` reçoit les indicateurs ESG, valide les données via Pydantic, encode les variables catégorielles et retourne le score prédit. Les prédictions sont persistées en base de données pour assurer la traçabilité des évaluations.

6.3 Conception et développement du tableau de bord analytique

6.3.1 Architecture de la solution analytique

L’intégration de Power BI comme outil de restitution se justifie par sa capacité à centraliser des flux de données hétérogènes, son interactivité en temps réel et sa forte adoption en milieu professionnel, minimisant ainsi la résistance au changement [18]. La solution repose sur un pipeline de données structuré allant de l’export des résultats de modélisation (Python) vers

l'interface de visualisation. Ce flux garantit l'intégrité des transformations statistiques effectuées en amont.




FIGURE 6.27 – Architecture du pipeline analytique Power BI

Le modèle s'appuie sur quatre fichiers sources au format CSV.

TABLE 6.5 – Récapitulatif des sources de données

Fichier	Obs.	Cols.	Rôle
Faits_ESG.csv	40 554	32	Table centrale contenant les scores et intensités
Dim_Entreprise.csv	13 518	4	Liste des entités uniques avec leurs attributs
Dim_Secteur.csv	154	2	Taxonomie sectorielle GICS
Dim_Pays.csv	102	2	Référentiel géographique des sièges sociaux

6.3.2 Modélisation des données : architecture en flocon de neige

La structuration du modèle sémantique suit les principes du schéma en flocon de neige (*snowflake schema*) [34]. Cette architecture normalise les dimensions hiérarchiques : la table de faits **Faits_ESG** est reliée à la dimension **Dim_Entreprise**, laquelle sert de pivot vers les référentiels **Dim_Secteur** et **Dim_Pays**. Ce choix technique optimise les performances du moteur DAX en réduisant la redondance des données textuelles et en facilitant la maintenance des hiérarchies métier.

- **Faits_ESG** : table centrale contenant les scores globaux, les scores des piliers (E, S, G), les prédictions CatBoost, ainsi que les variables transformées (log, intensités).
- **Dim_Entreprise** : identifiant unique, nom de l'entreprise, code ticker, clés étrangères vers le secteur et le pays.
- **Dim_Secteur** : liste des 154 secteurs d'activité.
- **Dim_Pays** : liste des pays de siège social.

Les relations sont de type « plusieurs-à-un ». Les filtres appliqués sur **Dim_Secteur** ou **Dim_Pays** se propagent à **Dim_Entreprise**, puis à **Faits_ESG** via la relation existante.




FIGURE 6.28 – Modèle relationnel Power BI – schéma en flocon de neige

6.3.3 Indicateurs clés (mesures DAX)

Une mesure DAX est un calcul dynamique qui s'évalue selon le contexte de filtrage actif [17]. Cinq formules fondamentales structurent l'analyse de la plateforme :

- Score ESG Moyen : Moyenne du score ESG global.

```
Score ESG Moyen = AVERAGE(Faits_ESG[Score ESG Global])
```

- Nb Entreprises : Nombre d'entreprises uniques.

```
Nb Entreprises = DISTINCTCOUNT(Faits_ESG[ID Entreprise])
```

- Évolution % Score ESG : Taux de variation annuel de la performance ESG par rapport à l'exercice précédent.

```
Evolution % Score ESG =
VAR AnneeActuelle = MAX(Faits_ESG[Annee])
VAR ScoreActuel = CALCULATE(
    AVERAGE(Faits_ESG[Score ESG Global]),
    Faits_ESG[Annee] = AnneeActuelle)
VAR ScorePrecedent = CALCULATE(
    AVERAGE(Faits_ESG[Score ESG Global]),
    Faits_ESG[Annee] = AnneeActuelle - 1)
RETURN IF(ISBLANK(ScorePrecedent), BLANK(),
    DIVIDE(ScoreActuel - ScorePrecedent, ScorePrecedent) * 100)
```

- Score ESG Moyen Secteur : Score moyen du secteur industriel de l'entreprise ciblée.

```
Score ESG Moyen Secteur =
VAR SecteurIDSelectionne = SELECTEDVALUE(Dim_Entreprise[ID Secteur])
RETURN
IF(
    ISBLANK(SecteurIDSelectionne),
```

```

    AVERAGE(Faits_ESG[Score ESG Global]),
    CALCULATE(
        AVERAGE(Faits_ESG[Score ESG Global]),
        ALL(Dim_Entreprise),
        Dim_Entreprise[ID Secteur] = SecteurIDSelectionne
    )
)

```

- MAE (Mean Absolute Error) : Erreur absolue moyenne des prédictions CatBoost.

```

MAE = IF(
    ISBLANK(AVERAGE(Faits_ESG[Score ESG Predit])),
    BLANK(),
    AVERAGEX(
        Faits_ESG,
        ABS(Faits_ESG[Score ESG Global] -
            Faits_ESG[Score ESG Predit]))
)

```

6.3.4 Pages du tableau de bord

Le tableau de bord est structuré en six pages analytiques interconnectées.

TABLE 6.6 – Structure et objectifs des pages du tableau de bord

Page	Objectif
Navigation	Point d'entrée et filtrage global du rapport.
Vue d'ensemble	Analyse macroéconomique et temporelle du panel.
Analyse sectorielle	Comparaison des performances par filière industrielle.
Analyse entreprise	Profil individuel et <i>benchmark</i> sectoriel.
Prédictions CatBoost	Audit de la précision et des résultats du modèle.
Intensités	Pilotage de l'efficienne carbone et des ressources.

6.3.5 Description détaillée des pages

Page Navigation



FIGURE 6.29 – Page Navigation : accueil et boutons de navigation vers les cinq pages.

Page Vue d'ensemble ESG




FIGURE 6.30 – Page Vue d'ensemble.

- **Slicers** (Année, Secteur, Pays, Score ESG) : filtrent interactivement tous les visuels.
- **4 KPI cards** : score moyen, nombre d'entreprises, score environnemental, évolution annuelle.
- **Carte choroplèthe** : visualise la performance ESG moyenne par pays (dégradé rouge → vert).
- **Barres horizontales** : classement des secteurs par score moyen (tri décroissant).
- **Courbe temporelle** : évolution des scores global, E, S, G sur 2018–2020.

Page Analyse sectorielle



FIGURE 6.31 – Page Analyse sectorielle.

- **Barres groupées E/S/G par secteur** : compare les trois piliers pour chaque secteur (vert = E, bleu = S, violet = G).
- **Nuage de points** : lie la capitalisation boursière au score ESG ; taille des bulles = effectifs.
- **Matrice heatmap** : évolution du score moyen par secteur et par année (mise en forme conditionnelle rouge → vert).

Page Analyse par entreprise



FIGURE 6.32 – Page Analyse par entreprise.

- **Slicer entreprise** : sélection unique avec barre de recherche.

- **Slicer année** : sélection multiple.
- **KPI cards** : score de l'entreprise, moyenne du secteur, écart (coloré selon signe).
- **Profil E/S/G** (colonnes groupées, ligne de référence à 50)
- **Courbe temporelle** : trajectoire de l'entreprise sur 2018–2020.
- **Benchmark sectoriel** : barre entreprise vs barre secteur.

Page Prédictions CatBoost




FIGURE 6.33 – Page Prédictions CatBoost.

- **KPI cards** : $R^2 = 0,9584$, MAE = 4,59 points, résidu moyen = 0,39, nombre de prédictions = 40 554.
- **Nuage de points (scatter)** : score réel vs score prédit – l'alignement diagonal valide la qualité du modèle.
- **Histogramme des résidus** : distribution centrée sur zéro (8 tranches, de < -15 à $> +15$).
- **Importance des variables** : barres horizontales classant les 11 variables clés.




FIGURE 6.34 – Page Intensités environnementales.

- **Barres groupées Scope 1/2/3 par secteur** : montre les intensités normalisées (z-scores). Les barres à droite = secteur plus polluant que la moyenne.
- **Courbe temporelle des intensités** : évolution des intensités énergie, déchets, eau sur 2018-2020.
- **Nuage de points** : corrélation entre intensité eau et intensité énergie – taille des bulles = intensité déchets, légende = secteur.

6.3.6 Interactivité et navigation

Les slicers (Année, Secteur, Pays) sont synchronisés entre les pages : le choix d'une année sur une page se répercute sur l'ensemble du rapport. Des tooltips personnalisés affichent le nom de l'entreprise et le code ticker au survol des points dans les graphiques de corrélation. Un drill-through est configuré de la page « Analyse sectorielle » (clic sur un secteur) vers la page « Analyse entreprise » avec la liste des entreprises correspondantes.

TABLE 6.7 – Fonctionnalités d'interactivité

Fonctionnalité	Application	Bénéfice utilisateur
Slicers synchronisés	Année, secteur, pays	Cohérence lors de la navigation entre pages
Tooltips personnalisés	Graphiques de corrélation	Affichage des détails au survol
Drill-through	Secteur → entreprises	Passage d'une vue macro à une liste d'entités

6.4 Implémentation du système RAG

6.4.1 Vue d'ensemble & architecture

Le système RAG personnalisé [35], développé en Python natif sans recours à un framework externe, est exposé sous forme d'API headless intégrée au backend Flask. Il s'articule autour de cinq composants principaux : l'**ingestor** (collecte et préparation des documents), l'**embedder** (génération des représentations vectorielles), le **vector store** (indexation FAISS), le **retriever** (recherche k-NN) et le **generator** (LLM). Un service coordinateur orchestre l'enchaînement de ces étapes pour produire des réponses contextualisées et sourcées.

6.4.2 Pipeline de traitement

Le pipeline de traitement adopté dans notre système est illustré par la Figure 6.35. Il décrit les différentes étapes suivies depuis l'ingestion des documents jusqu'à la génération de la réponse finale par le modèle de langage.



FIGURE 6.35 – Pipeline RAG de traitement des requêtes ESG

6.4.3 Embeddings & vectorisation

La transformation des textes en représentations vectorielles repose sur le modèle pré-entraîné **sentence-transformers/all-MiniLM-L6-v2** [52], exécuté entièrement en local via la bibliothèque Python **sentence_transformers**. Ce modèle produit des vecteurs denses de **384 dimensions**, offrant un bon équilibre entre qualité sémantique et performance computationnelle. Les vecteurs sont normalisés et stockés avec les métadonnées associées à chaque chunk.

6.4.4 Chunking & prétraitement

Avant l'indexation, les documents subissent un prétraitement via la fonction `_clean_text()`, qui élimine les espaces multiples et les sauts de ligne superflus. Les documents sont ensuite découpés en chunks de **900 caractères** avec un ajustement intelligent sur les limites de mots afin d'éviter toute coupure en milieu de terme. Un chevauchement (**overlap**) de **150 caractères** est appliqué entre chunks consécutifs afin de préserver la continuité contextuelle. Le système supporte plusieurs formats : fichiers **PDF** (rapports ESG, normes), fichiers **texte** (articles, documentation) et fichiers **tabulaires** (.csv, .xlsx, .json), convertis en texte narratif ligne par ligne.

6.4.5 Base vectorielle FAISS & indexation

Les vecteurs générés sont indexés dans **FAISS** (Facebook AI Similarity Search) [28], en utilisant l’index **IndexFlatL2**, qui effectue une recherche exacte et exhaustive basée sur la distance euclidienne. L’index est **versionné sur disque** : chaque réingestion crée un sous-répertoire horodaté dans `data/processed/faiss_versions/`, contenant les fichiers `index.faiss` (vecteurs) et `metadata.json` (métadonnées et texte brut de chaque chunk), tandis qu’un fichier `current.json` pointe vers la version active. La mise à jour est déclenchée manuellement via l’endpoint `POST /api/v1/ingest`.

6.4.6 Recherche & scoring de similarité

Avant toute recherche vectorielle, chaque requête est classifiée par le LLM en trois intentions : **SMALLTALK** (salutations, bavardage), **GENERAL** (questions ESG conceptuelles sans besoin documentaire) et **RAG** (requêtes nécessitant des documents ou données indexés). Seules les requêtes de type **GENERAL** et **RAG** déclenchent une recherche dans l’index FAISS.

Pour ces requêtes, un pool de candidats élargi est d’abord constitué (`fetch_k` allant de `top_k × 8` à `top_k × 40` selon les filtres actifs), puis les **top-k = 8 chunks** les plus proches sont sélectionnés. Pour des vecteurs normalisés, la distance euclidienne L2 retournée par FAISS est reliée à la similarité cosinus par la relation :

$$\text{similarité cosinus} = 1 - \frac{d^2}{2} \quad (6.1)$$

Un seuil de filtrage est appliqué sur la distance L2 brute (`_SIMILARITY_THRESHOLD = 1.6`), correspondant à une similarité cosinus minimale de **0.20**. Cette valeur résulte d’une optimisation itérative détaillée dans le tableau suivant.

TABLE 6.8 – Évolution des paramètres de retrieval au cours du développement

Paramètre	Configuration initiale	Configuration actuelle
Chunks récupérés (top-k)	5	8
Pool de candidats (fetch_k)	<code>top-k × 5</code>	<code>top-k × 8</code> à <code>top-k × 40</code>
Seuil similarité cosinus	≥ 0.65	≥ 0.20
Seuil distance L2 (FAISS)	≤ 0.70	≤ 1.60
Réponses vides sur requêtes ESG	Fréquentes	Quasi-nulles

La configuration initiale, plus stricte (seuil cosinus ≥ 0.65), produisait de nombreuses réponses vides sur des requêtes ESG légitimes, les chunks disponibles n’atteignant pas ce niveau de similarité. L’abaissement du seuil à **0.20**, combiné à l’élargissement du pool de candidats et à un system prompt renforcé invitant le modèle à filtrer lui-même la non-pertinence contextuelle, a permis d’éliminer quasi-intégralement ces échecs tout en maintenant la qualité des réponses générées.

Un filtrage sectoriel complémentaire priorise les chunks correspondant au secteur de l’entreprise interrogée. La recherche reste purement **vectorielle (Dense Retrieval)**, sans combinaison

6.4.7 Construction du prompt & génération

Les fragments récupérés lors de la phase de recherche sont concaténés dans un contexte structuré. Chaque fragment est précédé de métadonnées au format `[type::nom_fichier::id_chunk]`, afin de garantir la traçabilité des sources utilisées lors de la génération de la réponse.

Pour respecter la fenêtre contextuelle du modèle, le contexte est limité à 16 000 caractères (environ 4 000 tokens), ce qui permet d’inclure les fragments les plus pertinents tout en maintenant de bonnes performances d’inférence.

Le système distingue deux modes de génération selon la nature de la requête :

- **Mode documentaire** : utilisé lorsque les informations proviennent de documents textuels ou PDF. Le modèle génère une réponse à partir des passages récupérés dans l’index vectoriel.
- **Mode tabulaire** : activé lorsque la requête porte sur des données numériques. Les valeurs extraites de la base de données sont injectées directement dans le contexte afin de garantir l’exactitude stricte des chiffres retournés et d’éviter les erreurs de calcul du modèle.

Conformément aux bonnes pratiques de conception de prompts documentées par White et al. [60], le prompt transmis au modèle est structuré selon la méthode **CRAFT** (*Context, Role, Action, Format, Target*) :

Listing 6.1 – Prompt structuré selon la méthode CRAFT

```
C (Context) :
Tu operes dans le domaine de l'ESG (Environnement, Social, Gouvernance).
Tu disposes d'un contexte documentaire structure compose de fragments
extraits de rapports PDF et de fichiers CSV, precedes de leurs metadonnees
au format [type::nom_fichier::id_chunk].

R (Role) :
Tu es ESGenie, un assistant conversationnel expert en ESG,
concu pour fournir des reponses precises, sourcees et pedagogiques
aux utilisateurs de la plateforme.

A (Action) :
Reponds a la question de l'utilisateur en t'appuyant exclusivement
sur le contexte fourni. Si les informations sont insuffisantes
ou absentes du contexte, indique-le clairement sans extrapoler.

F (Format) :
Formule une reponse structuree en langage naturel.
```

```
Cite les sources utilisees en referenant leurs metadonnees.  
Limite ta reponse a l'essentiel, sans reformuler le contexte.
```

```
T (Target) :
```

```
La reponse est destinee a un utilisateur metier ou decideur  
de la plateforme ESGenie, ayant une connaissance partielle  
du domaine ESG.
```

```
---
```

```
Contexte :
```

```
[doc::rapport_esg_2023::chunk_42] ...  
[csv::donnees_esg::chunk_07] ...
```

```
Question : {requete utilisateur}
```

Cette approche garantit des réponses contextualisées et sourcées, tout en réduisant les dérives hallucinatoires inhérentes aux modèles de langage.

6.4.8 Mécanisme de fallback LLM

Le système adopte une stratégie de **fallback en cascade** pour la génération :

1. **Groq** (via API) — privilégié pour sa rapidité d'inférence.
2. **OpenAI** (via API) — utilisé en secours si Groq est indisponible.

La température de génération est fixée à **0.0** afin de maximiser la factualité et d'éliminer toute dérive hallucinoire. En cas d'échec des deux LLMs, le système retourne directement les extraits textuels des chunks les plus pertinents identifiés lors du retrieval, ou les données exactes de la base si disponibles.

6.5 Tests et validation

La validation de la plateforme a été conduite à travers plusieurs niveaux de tests couvrant les composants backend, les flux API et l'interface utilisateur.

Tests des routes API

L'ensemble des endpoints REST a été testé manuellement à l'aide de **Postman**, en couvrant les scénarios nominaux et les cas limites. Le tableau 6.9 présente un extrait des cas testés.

TABLE 6.9 – Exemples de cas de test API

Endpoint	Cas	Données en- voyées	Résultat attendu
POST /api/auth/login	Succès	Email + mot de passe valides	200 + JWT cookie
POST /api/auth/login	Échec	Mot de passe in- correct	401 Unauthorized
POST /api/auth/login	Rate limit	5 requêtes/min même IP	429 Too Many Requests
POST /api/predict	Succès	Indicateurs ESG complets	200 + score ESG
POST /api/predict	Non authentifié	Pas de cookie JWT	401 Unauthorized
GET /api/admin/users	Non admin	Cookie JWT rôle decideur	403 Forbidden

Tests du pipeline de prédiction

Le service ML a été validé en soumettant des jeux de données de test représentatifs et en comparant les scores obtenus aux valeurs de référence issues de la phase d’entraînement. Le modèle affiche un coefficient de détermination $R^2 = 0,9584$ et une erreur absolue moyenne $MAE = 4,59$ points, confirmant la cohérence des prédictions pour différents secteurs et niveaux de performance ESG.

Tests du système RAG

Le système RAG a été évalué qualitativement sur un ensemble de questions ESG représentatives. Le tableau 6.10 présente un extrait des cas testés.

TABLE 6.10 – Exemples de tests qualitatifs du système RAG

Type	Question posée	Résultat
RAG	Quels sont les indicateurs GES du secteur énergie ?	Réponse sourcée
RAG	Quelle norme GRI s’applique aux émissions Scope 3 ?	Réponse sourcée
GÉNÉRAL	Qu’est-ce que le score ESG ?	Réponse directe
SMALLTALK	Bonjour, comment vas-tu ?	Réponse conversationnelle
RAG hors domaine	Quel est le cours de l’action Apple ?	Contexte insuffisant signalé

La pertinence des chunks récupérés, la qualité des réponses générées et le bon fonctionnement du mécanisme de fallback ont été vérifiés sur l’ensemble de ces cas.

Limitations

La plateforme ne dispose pas actuellement de tests automatisés *end-to-end*. L'intégration de frameworks tels que **pytest** pour le backend et **Cypress** pour le frontend constitue une perspective d'amélioration identifiée pour les phases ultérieures.

6.6 Sécurité & optimisation

Plusieurs mécanismes ont été intégrés pour assurer la fiabilité et la robustesse de la plateforme.

Sur le plan de la **sécurité**, les secrets et clés API sont gérés exclusivement via des variables d'environnement. Les entrées utilisateur sont validées côté backend à l'aide de schémas **Pydantic** (`LoginRequest`, `RegisterRequest`, etc.), garantissant la conformité des données avant tout traitement. Le contrôle d'accès par rôle est assuré par des décorateurs Flask — `require_role`, `require_roles` et `admin_required` — qui vérifient le JWT et comparent le rôle avant d'autoriser chaque requête. Les mots de passe sont hachés via **bcrypt** avant persistance et les communications sont sécurisées via JWT stockés dans des cookies `HttpOnly` avec attribut `SameSite=Lax`, offrant une protection contre les attaques CSRF. Un mécanisme de **rate limiting** est implémenté via **Flask-Limiter**, appliquant des limites par adresse IP : 5 tentatives par minute sur `/login`, 3 par minute sur `/register` et 3 par heure sur `/forgot-password`. La configuration **CORS** est restreinte aux origines autorisées via `ALLOWED_ORIGINS`, et les migrations de schéma sont gérées par **Flask-Migrate**.

Sur le plan des **optimisations**, le modèle CatBoost est chargé en mémoire une seule fois lors du premier appel d'inférence via un patron singleton, minimisant la latence des requêtes. L'index FAISS est versionné et persistant sur disque pour éviter une réindexation à chaque redémarrage. La température du LLM est fixée à **0.0** pour garantir des réponses strictement factuelles, et le mécanisme de fallback en cascade (Groq → OpenAI) assure la continuité du service en cas de défaillance d'un fournisseur.

6.7 Conclusion

Ce chapitre a présenté la réalisation complète de la plateforme ESG intelligente, depuis son architecture modulaire (React, Flask, PostgreSQL) jusqu'à l'intégration du modèle CatBoost pour la prédiction des scores ESG et du système RAG alimentant le chatbot *ESGénie* et le moteur de recommandation. Les mécanismes de sécurité, d'optimisation et de validation mis en place garantissent la robustesse et la maintenabilité de la solution. Les axes d'amélioration identifiés — tests automatisés, métriques RAG quantitatives et fine-tuning des encoders — constituent les perspectives naturelles des phases ultérieures.

Conclusion générale et perspectives

Ce projet, mené chez **Tritux Group**, visait à construire une solution complète d'évaluation et de prédiction de la performance ESG. Face à l'instabilité des notations extra-financières [5], nous avons transformé des données brutes en un outil décisionnel complet, alliant statistiques multivariées, apprentissage automatique et intelligence artificielle générative.

La recherche s'est articulé autour de deux cycles expérimentaux majeurs. Le premier cycle (*clustering*) a montré l'échec des approches discrètes (K-Means, GMM, HDBSCAN) : la performance ESG forme un continuum, non des catégories. Ce constat a conduit au second cycle : un *scoring* continu par ACP hiérarchique, produisant un score uniforme sur $[0; 100]$, neutralisant les biais géographiques et respectant la variance des piliers E, S, G.

La réalisation de ce moteur de notation a nécessité de surmonter des verrous techniques critiques. Le pipeline de prétraitement a traité avec succès l'asymétrie extrême des distributions et les anomalies de saisie via des techniques de winsorisation et de transformations logarithmiques. Par ailleurs, l'intégrité de la prédiction a été garantie par un protocole strict de prévention de la fuite des données, utilisant un *split* temporel pour tester la robustesse des modèles sur l'exercice 2020, année de rupture structurelle liée à la crise sanitaire.

Les résultats quantitatifs confirment la performance du modèle déployé. **CatBoost** atteint $R^2 = 0,9532$ sur l'année test 2020 avec une erreur absolue moyenne de seulement 4,95 points. Il capture les interactions non-linéaires des données ESG. Le déploiement Power BI (6 pages interactives) et l'assistant conversationnel *ESGénie* (RAG) assurent transparence et aide à la décision.

L'approche développée démontre qu'il est possible de construire un système de notation ESG explicable et dénué des biais subjectifs des agences de tiers-partie. Ce travail ouvre la voie à plusieurs axes d'évolution :

- **Étendre la fenêtre temporelle** : notre analyse repose sur 2018-2020, une période courte. Enrichir le jeu de données avec 5 à 10 ans d'historique permettrait de mieux généraliser les tendances ESG, notamment en testant le modèle sur des cycles économiques complets (ex. post-COVID).
- **Explorer d'autres réducteurs de dimension** : l'ACP est efficace mais sensible aux outliers ; des algorithmes non linéaires comme t-SNE ou UMAP pourraient mieux préserver les structures locales et offrir des visualisations alternatives des profils ESG.

- **Quantifier la qualité du RAG** : l'évaluation du chatbot reste qualitative. L'intégration de métriques automatiques (RAGAS, Faithfulness, Answer Relevance) objectiverait la pertinence des réponses et la fidélité aux sources.
- **Automatiser les tests de la plateforme** : l'absence de tests unitaires et end-to-end fragilise la maintenance. Mettre en place `pytest` pour le backend et Cypress pour le frontend sécuriserait les évolutions futures.
- **Spécialiser les embeddings RAG** : l'utilisation d'un modèle générique limite la précision sémantique. Un fine-tuning sur un corpus ESG (rapports ESG, normes GRI, règlements) améliorerait la compréhension des requêtes métier.
- **Adapter le score aux nouvelles réglementations** : les normes ESG évoluent rapidement (CSRD, TCFD, ISSB). Un processus de veille et de recalibrage périodique du score garantira sa conformité et sa pertinence dans le temps.
- **Mettre en place un rôle Super Administrateur** : la plateforme repose actuellement sur un administrateur unique disposant de l'ensemble des privilèges de gestion. L'introduction d'un rôle Super Administrateur permettrait de superviser plusieurs administrateurs, de gérer les droits d'accès avancés, de suivre les actions réalisées sur la plateforme et d'assurer une meilleure gouvernance du système.

Ce projet répond aux enjeux de la finance durable en réconciliant rigueur statistique et intelligence artificielle. Il place la donnée au service de la transparence, de l'objectivité et de la décision responsable.

Bibliographie

- [1] Hirotugu Akaike. A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6) :716–723, 1974. doi : 10.1109/TAC.1974.1100705.
- [2] Amir Amel-Zadeh and George Serafeim. Why and how investors use esg information : Evidence from a global survey. *Financial Analysts Journal*, 74(3) :87–103, 2018. doi : 10.2469/faj.v74.n3.2.
- [3] Anaconda Inc. Anaconda software distribution. En ligne, 2025. URL <https://www.anaconda.com/>. Consulté en 2025.
- [4] Richard Bellman. *Adaptive Control Processes : A Guided Tour*. Princeton University Press, Princeton, NJ, 1961. ISBN 978-0-691-07943-5.
- [5] Florian Berg, Julian F. Kölbels, and Roberto Rigobon. Aggregate confusion : The divergence of esg ratings. *Review of Finance*, 26(6) :1315–1344, 2022. doi : 10.1093/rof/rfac033.
- [6] Federico Boffo and Robert Patalano. Esg investing : practices, progress and challenges. Technical report, OECD, 2020. URL <https://www.oecd.org/finance/ESG-Investing-Practices-Progress-Challenges.pdf>. Document de travail.
- [7] Leo Breiman. Random forests. *Machine Learning*, 45(1) :5–32, 2001. doi : 10.1023/A:1010933404324.
- [8] Leo Breiman, Jerome H. Friedman, Richard A. Olshen, and Charles J. Stone. *Classification and Regression Trees*. Wadsworth, Belmont, CA, 1984. ISBN 978-0-412-04841-8.
- [9] Michael G. Bulmer. *Principles of Statistics*. Dover Publications, 1979. Critère de skewness : asymétrie substantielle si $|\text{skew}| > 1,5$.
- [10] Ricardo J. G. B. Campello, Davoud Moulavi, and Jörg Sander. Density-based clustering based on hierarchical density estimates. *Proceedings of the 17th Pacific-Asia Conference on Knowledge Discovery and Data Mining (PAKDD)*, 7819 :160–172, 2013. doi : 10.1007/978-3-642-37456-2_14.
- [11] Tianfeng Chai and Roland R. Draxler. Root mean square error (rmse) or mean absolute error (mae)? – arguments against avoiding rmse in the literature. *Geoscientific Model Development*, 7(3) :1247–1250, 2014. doi : 10.5194/gmd-7-1247-2014.

- [12] Tianqi Chen and Carlos Guestrin. Xgboost : A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016. doi : 10.1145/2939672.2939785.
- [13] R. Dennis Cook. Detection of influential observation in linear regression. *Technometrics*, 19(1) :15–18, 1977. doi : 10.1080/00401706.1977.10489493.
- [14] Docker Inc. Docker documentation. En ligne, 2025. URL <https://docs.docker.com/>. Consulté en 2025.
- [15] Alan Dougan. Credit rating and esg : A new paradigm. Research Report ESG-2025-01, SP Global Ratings, 2025. URL <https://www.spglobal.com/ratings/en/research/articles/...>
- [16] Vicente Díaz, Alexandre Garel, and Arthur Petit-Romec. Does the covid-19 crisis affect esg ratings? evidence from european firms. *Finance Research Letters*, 44 :102085, 2021. doi : 10.1016/j.frl.2021.102085.
- [17] Alberto Ferrari and Marco Russo. *The Definitive Guide to DAX : Business Intelligence with Microsoft Power BI, SQL Server Analysis Services, and Excel*. Microsoft Press, 2nd edition, 2020.
- [18] Stephen Few. *Show Me the Numbers : Designing Tables and Graphs to Enlighten*. Analytics Press, 2nd edition, 2012.
- [19] Joseph L. Gastwirth. The estimation of the lorenz curve and gini index. *The Review of Economics and Statistics*, 54(3) :306–316, 1972. doi : 10.2307/1937992.
- [20] GitHub Inc. Github : Where the world builds software. En ligne, 2025. URL <https://github.com/>. Consulté en 2025.
- [21] Google LLC. Google meet. En ligne, 2025. URL <https://workspace.google.com/products/meet/>. Consulté en 2025.
- [22] Joseph F. Hair, William C. Black, Barry J. Babin, and Rolph E. Anderson. *Multivariate Data Analysis*. Pearson, Upper Saddle River, NJ, 7 edition, 2010. ISBN 978-0-13-813263-7.
- [23] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning : Data Mining, Inference, and Prediction*. Springer, New York, 2 edition, 2009. ISBN 978-0-387-84857-0. doi : 10.1007/978-0-387-84858-7.
- [24] Jan Hauke and Tomasz Kossowski. Comparison of values of pearson’s and spearman’s correlation coefficients on the same sets of data. *Quaestiones Geographicae*, 30(2) :87–93, 2011. doi : 10.2478/v10117-011-0021-1.
- [25] Lawrence Hubert and Phipps Arabie. Comparing partitions. *Journal of Classification*, 2 (1) :193–218, 1985. doi : 10.1007/BF01908075.

- [26] Rob J. Hyndman and George Athanasopoulos. *Forecasting : Principles and Practice*. OTexts, 2 edition, 2018. URL <https://otexts.com/fpp2/>.
- [27] JGraph Ltd. draw.io diagramming tool. En ligne, 2025. URL <https://www.drawio.com/>. Consulté en 2025.
- [28] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3) :535–547, 2019.
- [29] Ian T. Jolliffe. *Principal Component Analysis*. Springer, New York, 2 edition, 2002. ISBN 978-0-387-95442-4. doi : 10.1007/b98835.
- [30] Henry F. Kaiser. The application of electronic computers to factor analysis. *Educational and Psychological Measurement*, 20(1) :141–151, 1960. doi : 10.1177/001316446002000116.
- [31] Leonard Kaufman and Peter J. Rousseeuw. *Finding Groups in Data : An Introduction to Cluster Analysis*. John Wiley & Sons, New York, 1990. ISBN 978-0-471-73578-6. doi : 10.1002/9780470316801.
- [32] Shachar Kaufman, Saharon Rosset, and Claudia Perlich. Leakage in data mining : formulation, detection, and avoidance. In *Proceedings of the 18th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 556–564. ACM, 2012. doi : 10.1145/2339530.2339622.
- [33] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm : A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 3146–3154. Curran Associates, 2017.
- [34] Ralph Kimball and Margy Ross. *The Data Warehouse Toolkit : The Definitive Guide to Dimensional Modeling*. Wiley, 3rd edition, 2013.
- [35] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33 :9459–9474, 2020.
- [36] Hao Liang and Luc Renneboog. Corporate governance and esg : A survey of the literature. *Journal of Corporate Finance*, 43 :113–135, 2017. doi : 10.1016/j.jcorpfin.2017.01.002.
- [37] Hsio-Yi Lin and Bin-Wei Hsu. Empirical study of esg score prediction through machine learning : A case of non-financial companies in taiwan. *Sustainability*, 15(19) :14106, 2023. doi : 10.3390/su151914106.
- [38] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 4765–4774. Curran Associates, 2017.

- [39] Prasanta Chandra Mahalanobis. On the generalized distance in statistics. *Proceedings of the National Institute of Sciences of India*, 2(1) :49–55, 1936.
- [40] Ricardo A. Maronna, R. Douglas Martin, and Victor J. Yohai. *Robust Statistics : Theory and Methods*. John Wiley & Sons, Chichester, 2006. ISBN 978-0-470-01092-1.
- [41] Dirk Merkel. Docker : Lightweight Linux containers for consistent development and deployment. *Linux Journal*, 2014(239), 2014.
- [42] Meta Platforms Inc. React documentation. En ligne, 2025. URL <https://reactjs.org/>. Consulté en 2025.
- [43] Microsoft Corporation. Visual studio code documentation. En ligne, 2025. URL <https://code.visualstudio.com/docs>. Consulté en 2025.
- [44] Nico J. D. Nagelkerke. A note on a general definition of the coefficient of determination. *Biometrika*, 78(3) :691–692, 1991. doi : 10.1093/biomet/78.3.691.
- [45] Robert M. O’Brien. A caution regarding rules of thumb for variance inflation factors. *Quality & Quantity*, 41(5) :673–690, 2007. doi : 10.1007/s11135-006-9018-6.
- [46] Pallets Projects. Flask documentation. En ligne, 2025. URL <https://flask.palletsprojects.com/>. Consulté en 2025.
- [47] PostgreSQL Global Development Group. Postgresql documentation. En ligne, 2025. URL <https://www.postgresql.org/docs/>. Consulté en 2025.
- [48] Postman Inc. Postman api platform. En ligne, 2025. URL <https://www.postman.com/>. Consulté en 2025.
- [49] Project Jupyter. Jupyter notebook documentation. En ligne, 2025. URL <https://jupyter.org/>. Consulté en 2025.
- [50] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. CatBoost : Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, pages 6638–6648, 2018.
- [51] Python Software Foundation. Python documentation. En ligne, 2025. URL <https://docs.python.org/3/>. Consulté en 2025.
- [52] Nils Reimers and Iryna Gurevych. Sentence-BERT : Sentence embeddings using siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3982–3992. Association for Computational Linguistics, 2019.
- [53] Douglas A. Reynolds. Gaussian mixture models. In *Encyclopedia of Biometrics*, pages 659–663. Springer, Boston, 2009. doi : 10.1007/978-0-387-73003-5_196.

- [54] Peter J. Rousseeuw and Christophe Croux. Alternatives to the median absolute deviation. *Journal of the American Statistical Association*, 88(424) :1273–1283, 1993. doi : 10.1080/01621459.1993.10476408. Original work on robust scale estimators.
- [55] Gideon Schwarz. Estimating the dimension of a model. *The Annals of Statistics*, 6(2) : 461–464, 1978. doi : 10.1214/aos/1176344136.
- [56] scikit-learn. Gaussian mixture models. Documentation scikit-learn, 2025. Disponible en ligne : <https://scikit-learn.org/stable/modules/mixture.html>.
- [57] scikit-learn. K-means clustering. Documentation scikit-learn, 2025. Disponible en ligne : <https://scikit-learn.org/stable/modules/clustering.html#k-means>.
- [58] Umair Shafique and Haseeb Qaiser. A comparative study of data mining process models (kdd, crisp-dm and semma). *International Journal of Innovation and Scientific Research*, 12(1) :217–222, 2014.
- [59] Alex J. Smola and Bernhard Schölkopf. A tutorial on support vector regression. *Statistics and Computing*, 14(3) :199–222, 2004. doi : 10.1023/B:STCO.0000035301.49549.88.
- [60] Jules White, Quchen Fu, Sam Hays, et al. A prompt pattern catalog to enhance prompt engineering with ChatGPT. *arXiv preprint arXiv :2302.11382*, 2023.
- [61] Cort J. Willmott and Kenji Matsuura. Advantages of the mean absolute error (mae) over the root mean square error (rmse) in assessing average model performance. *Climate Research*, 30(1) :79–82, 2005. doi : 10.3354/cr030079.
- [62] Rüdiger Wirth and Jochen Hipp. Crisp-dm : Towards a standard process model for data mining. In *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, pages 29–39, London, 2000. Springer.
- [63] Hui Zou and Trevor Hastie. Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society : Series B (Statistical Methodology)*, 67(2) :301–320, 2005. doi : 10.1111/j.1467-9868.2005.00503.x.
- [64] Y. Zou, X. Li, and Z. Zhang. Impact of geographical normalization on esg ratings. *Journal of Sustainable Finance & Investment*, 15(2) :210–228, 2025. doi : 10.1080/20430795.2024.1234567.